

分类号: TP311.5

单位代码: 10335

密 级: 无

学 号:

浙江大学

硕士学位论文



中文论文题目: 基于最优传输与排序学习的
增益模型研究

英文论文题目: Research on Uplift Modeling Based on
Optimal Transport and Learning to Rank

申请人姓名:

指导教师:

合作导师:

专业学位类别: 电子信息

专业学位领域: 软件工程

所在学院: 软件学院

论文提交日期 2025 年 12 月 23 日

基于最优传输与排序学习的增益模型
算法研究



论文作者签名: _____

指导教师签名: _____

论文评阅人 1: _____

评阅人 2: _____

评阅人 3: _____

评阅人 4: _____

评阅人 5: _____

答辩委员会主席: _____

委员 1: _____

委员 2: _____

委员 3: _____

委员 4: _____

委员 5: _____

答辩日期: _____

**Research on Uplift Modeling Based on Optimal
Transport and Learning to Rank**



Author's signature: _____

Supervisor's signature: _____

Thesis Reviewer 1: _____

Thesis Reviewer 2: _____

Thesis Reviewer 3: _____

Thesis Reviewer 4: _____

Thesis Reviewer 5: _____

Chair: _____
(Committee of oral defence)

Committeeman 1: _____

Committeeman 2: _____

Committeeman 3: _____

Committeeman 4: _____

Committeeman 5: _____

Date of oral defence: _____

浙江大学研究生学位论文独创性声明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得 浙江大学 或其他教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

学位论文作者签名：

签字日期：

年 月 日

学位论文版权使用授权书

本学位论文作者完全了解 浙江大学 有权保留并向国家有关部门或机构送交本论文的复印件和磁盘，允许论文被查阅和借阅。本人授权 浙江大学 可以将学位论文的全部或部分内容编入有关数据库进行检索和传播，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。

（保密的学位论文在解密后适用本授权书）

学位论文作者签名：

导师签名：

签字日期：

年 月 日

签字日期：

年 月 日

摘要

随着互联网技术的飞速发展，精准营销与智能广告投放已成为提升企业效益的关键手段。面向干预决策的增益模型 (Uplift Modeling) 旨在识别并触达对干预敏感的用户，以实现营销与广告领域的增量价值最大化。

然而，现有的增益模型在实际应用中面临着多重挑战：首先，观测数据中普遍存在的选择偏差 (Selection Bias)，即干预组 (Treatment Group) 和对照组 (Control Group) 的样本分布因非随机分配而存在系统性偏差，这会使得模型对增益效应的估计产生严重偏差；其次，现有的增益模型研究多侧重于对增益效应值的拟合精度，往往忽视了对实际营销投放决策至关重要的增益排序能力的直接优化。鉴于此，本文开展了基于分布对齐与排序学习的增益模型算法的研究，旨在设计一个能够协同分布对齐、响应拟合与排序学习的统一框架。具体而言，本文的研究内容和主要贡献总结如下：

(1) 针对观测数据中干预组与对照组特征分布差异导致的选择偏差问题，本文提出了最优传输 (Optimal Transport) 驱动分布对齐增益模型算法框架。该算法框架利用最优传输算法度量并最小化干预组与对照组表征分布间的差异，实现干预组与对照组在特征空间及结构层面的深度对齐，从而有效消除选择偏差，提升增益效应估计准确性。

(2) 针对增益模型中排序的重要性以及长尾分布带来的优化偏差难题，本文设计了样本密度加权的排序学习模块，有效提升了模型对主体数据的排序能力与鲁棒性。同时，针对多目标竞争导致排序学习抑制的问题，引入了 GradNorm 动态加权算法。该算法能够实时平衡增益效益估计、分布对齐与排序学习任务的梯度流，确保模型在消除偏差的同时，能够持续、充分地优化增益排序指标。

(3) 本文在 MovieLens-100K、Hillstrom-Man 与 Hillstrom-Woman 三个公开基准数据集上进行了大量实验，本文所提出的模型的性能均优于现有前沿基准模型，实验结果证明了模型对于解决观测数据样本的选择偏差问题与排序学习缺失问题的有效性。

关键词：增益模型，选择偏差，最优传输，排序学习

Abstract

With the rapid development of Internet technology, precision marketing and intelligent advertising have become critical strategies for enhancing enterprise efficiency. Uplift modeling, which focuses on intervention decision-making, aims to identify and target users who are sensitive to interventions, thereby maximizing incremental value in marketing and advertising. However, existing uplift models face multiple challenges in practical applications. First, selection bias is prevalent in observational data, where the sample distributions of the Treatment Group and the Control Group exhibit systematic discrepancies due to non-random assignment, leading to severe bias in uplift effect estimation. Second, existing research largely focuses on the fitting accuracy of uplift values, often neglecting the direct optimization of uplift ranking capabilities, which are crucial for actual marketing decision-making. To address these issues, this thesis conducts research on uplift modeling algorithms based on distribution alignment and learning to rank, aiming to design a unified framework that synergizes distribution alignment, response fitting, and ranking learning. Specifically, the research content and main contributions are summarized as follows:

(1) To address the selection bias caused by feature distribution discrepancies between the treatment and control groups in observational data, this thesis proposes an Optimal Transport-driven distribution alignment framework for uplift modeling. This framework utilizes optimal transport algorithms to measure and minimize the difference between the representation distributions of the treatment and control groups. By achieving deep alignment at both the feature space and structural levels, it effectively eliminates selection bias and improves the accuracy of uplift effect estimation.

(2) Addressing the importance of ranking in uplift modeling and the optimization bias caused by long-tail distributions, this thesis designs a sample density-weighted ranking learning module, which effectively enhances the model's ranking capability and robustness on the main body of data. Furthermore, to tackle the issue of ranking

learning suppression caused by multi-objective competition, the GradNorm dynamic weighting algorithm is introduced. This algorithm balances the gradient flows of uplift estimation, distribution alignment, and ranking learning tasks in real-time, ensuring that the model can continuously and fully optimize uplift ranking metrics while eliminating bias.

(3) Extensive experiments were conducted on three public benchmark datasets: MovieLens-100K, Hillstrom-Man, and Hillstrom-Woman. The proposed models consistently outperformed existing state-of-the-art baselines. The experimental results demonstrate the effectiveness of the proposed models in resolving selection bias in observational data and addressing the lack of ranking learning optimization.

Keywords: Uplift Modeling, Selection Bias, Optimal Transport, Learning to Rank

目录

摘要	i
Abstract	ii
图目录	III
表目录	IV
第 1 章 绪论	1
1.1 研究背景与意义	1
1.2 研究内容与贡献	6
1.3 本文的组织结构	9
第 2 章 研究现状和预备知识	11
2.1 增益模型的研究现状	12
2.1.1 因果推断与增益模型	12
2.1.2 基于元学习器的间接估计方法	14
2.1.3 基于树模型的直接建模方法	16
2.1.4 基于因果表征学习的深度建模方法	16
2.1.5 增益模型评估指标	18
2.1.6 现有研究的不足与挑战	19
2.2 选择偏差问题及其研究现状	20
2.2.1 选择偏差的来源与定义	20
2.2.2 解决选择偏差的研究现状	21
2.3 排序精度问题及其研究现状	24
2.3.1 排序学习问题的来源与定义	24
2.3.2 排序学习研究现状	24
2.3.3 现有研究的局限性	25
2.4 本章小结	25
第 3 章 基于 Sinkhorn 与样本密度排序的增益模型与评估办法	27
3.1 引言	27
3.2 问题描述与定义	30
3.2.1 因果推断框架与假设	30
3.2.2 选择偏差的数学刻画	31
3.2.3 排序精度与长尾干扰的数学刻画	31
3.2.4 符号定义	32
3.3 基于 Sinkhorn 与样本密度排序的增益模型框架	34
3.3.1 Y-Learner 增益预估基础网络	35
3.3.2 基于 Sinkhorn 算法的分布对齐模块	36

3.3.3	基于样本密度加权的排序优化模块	38
3.3.4	损失函数与训练算法	40
3.4	实验与分析	40
3.4.1	实验设置	41
3.4.2	结果与分析	45
3.4.3	消融实验	48
3.4.4	超参数敏感性分析	49
3.5	本章小结	51
第 4 章	GradNorm 增强的结构化排序增益模型与评估办法	52
4.1	引言	52
4.2	问题描述与定义	54
4.2.1	特征分布对齐的拓扑结构一致性问题	54
4.2.2	多任务学习中的梯度冲突与帕累托稳定	55
4.2.3	符号定义	56
4.3	GSDR 模型框架	57
4.3.1	FGW-OT 结构对齐模块	58
4.3.2	基于 GradNorm 的多目标梯度平衡策略	61
4.3.3	损失函数与训练算法	63
4.4	实验与分析	63
4.4.1	实验设置	64
4.4.2	结果与分析	65
4.4.3	FGW 结构对齐的几何可视化分析	67
4.4.4	消融实验	68
4.4.5	超参数敏感性分析	69
4.5	本章小结	70
第 5 章	总结与展望	72
5.1	本文研究总结	72
5.2	未来工作展望	73
参考文献		75
作者简介		85
致谢		86

图目录

图 1.1 增益模型驱动的智能营销决策流程 1

图 1.2 营销人群分类 2

图 1.3 选择偏差问题图 3

图 1.4 排序学习缺失引发的排序错位示意图 5

图 1.5 本文的组织结构示意图 10

图 2.1 本章节的研究框架 12

图 2.2 基于因果表征学习的模型架构 17

图 3.1 SDR 模型总体架构 34

图 3.2 SDR 模型性能指标随超参数变化的趋势分析 50

图 4.1 GSDR 模型总体框架 57

图 4.2 特征空间上的对齐效果对比 67

图 4.3 GSDR 模型性能指标随超参数变化的趋势分析 70

表目录

表 3.1	第三章符号说明	33
表 3.2	数据集统计信息	42
表 3.3	SDR 模型与基线模型的 CATE 估计准确性指标对比	47
表 3.4	SDR 模型与基线模型的增益排序指标对比	47
表 3.5	SDR 在 Hillstrom-Man 数据集上的消融实验结果	49
表 4.1	第四章符号说明	56
表 4.2	GSDR 模型与基线模型的 CATE 估计准确性指标对比	65
表 4.3	GSDR 模型与基线模型的增益排序指标对比	66
表 4.4	SDR 在 Hillstrom-Man 数据集上的消融实验结果	68

第 1 章 绪论

1.1 研究背景与意义

近年来，人工智能（Artificial Intelligence）技术的蓬勃发展正在重塑全球经济结构，以数据驱动的智能决策系统已成为数字经济的核心引擎。2021 年 12 月，国务院印发《“十四五”数字经济发展规划》，明确指出要“充分发挥数据要素作用”，推动“产业转型升级”，并强调利用大数据技术“推动个性化数据服务的发展”。随后，《数字中国建设整体布局规划》进一步提出要提升数字化服务水平，促进数字技术与实体经济深度融合。这深刻表明，在国家战略层面，如何高效利用海量数据资源，实现资源的最优配置与价值最大化，已成为推动经济高质量发展的关键命题。作为连接企业与用户的重要纽带，智能营销系统通过精准识别用户需求，不仅能够提升企业的运营效率，更能优化消费者的服务体验，对于释放内需潜力、构建双循环新发展格局具有重要的战略意义。

传统的营销与推荐系统主要依赖于响应模型（Response Model），即预测用




图 1.1 增益模型驱动的智能营销决策流程




图 1.2 营销人群分类

户产生购买或点击行为的概率。随着电子商务和移动互联网的迅猛发展，这种基于“相关性”的预测方法虽然在一定程度上提升了转化率，但也逐渐暴露出资源浪费与效率低下的问题。为应对这一挑战，面向因果推断的增益模型（Uplift Modeling）^[1]应运而生。如图 1.1 所示，与传统模型仅关注单一结果不同，增益模型作为一种融合了因果推断与机器学习的前沿技术，其核心旨在预测某种干预措施（如发放优惠券、投放广告）对个体用户产生的“增量效应”^[2,3]。通过深入分析反事实结果，如图 1.2 所示，增益模型能够将用户群体细分为四类：“虽干预也不转化（Lost Causes）”、“无论干预与否均转化（Sure Things）”、“因干预而不再转化（Sleeping Dogs）”以及“因干预而转化（Persuadables）”。其终极目标在于精准识别出其中的“营销敏感用户（Persuadables）”，从而在资源有限的情况下最大化营销产出。

回顾增益模型的发展历程，其演进脉络清晰地映射了人工智能从关联挖掘向因果探究的跨越。早期的研究主要依赖于差分响应模型^[4]，即分别对干预组和对照组训练独立的响应模型，通过差分计算增益，这种方法虽然直观但往往受限于累积误差。随后，基于树模型的算法（如 Uplift Trees）^[2]通过改进分裂准则直接优化增益分布，显著提升了预测的稳定性。近年来，随着深度学习技术的突破，基于表征学习（Representation Learning）的因果推断方法（如 TarNet、




图 1.3 选择偏差问题图

CFR-Net)^[5] 逐渐成为主流，它们通过学习平衡表征来消除混淆偏差，使得在高维稀疏数据下的增益估计更加精准可靠。这一技术的成熟极大地推动了其在工业界的落地应用。例如，在电商促销活动中，阿里巴巴利用深度增益模型构建了精细化的红包发放系统，不仅精准识别出价格敏感型用户，还有效规避了向自然转化用户发放补贴造成的预算浪费，显著提升了投资回报率（ROI）^[6,7]；美团外卖则通过引入因果推断框架优化智能调度与用户补贴策略，在复杂的供需博弈中实现了运力资源的最优配置与订单量的动态平衡。这些成功案例充分证明，增益模型已从理论研究走向实际应用，成为实现精细化运营、推动数字经济降本增效的关键技术手段^[3]。

然而在实际业务中，历史数据的收集往往并非基于理想的随机对照试验（RCT），而是基于特定的运营策略（如只给高活用户发券）。这种非随机的分配机制导致干预组与对照组在特征分布上存在显著的系统性差异。模型在训练时难以区分观测到的结果差异究竟是由于干预本身引起的，还是由用户固有的特征差异（如购买力高低）导致的。这种混淆效应直接导致模型对条件平均增益效应（CATE）的估计产生严重偏差。这就是观测数据中存在的选择偏差问题。

选择偏差（Selection Bias）是观测数据中普遍存在且难以避免的现象。如图 1.3 所示。在历史数据收集过程中，干预措施的分配往往不是随机的，而是受到特定策略或用户自身属性的影响^[8]。这种非随机的分配机制导致干预组（Treated

Group) 与对照组 (Control Group) 的特征分布存在显著差异^[9]。如果不加处理直接建模, 模型会将用户自身的属性效应 (如 “具有较高自然转化倾向”) 误判为干预带来的增益效应 (如 “因干预措施诱导而产生转化”)。这种因果效应估计的失真, 会导致企业错误地评估营销策略的有效性^[10]。传统的去偏方法 (如样本重加权、特征对齐) 虽然能够消除分布差异, 但往往以牺牲模型的拟合能力为代价。这意味着在消除选择偏差的同时, 必须精心设计机制以保留对增益预测至关重要的特征信息, 如何在两者之间找到最优平衡点, 是一个亟待解决的难点。因此, 本研究首先聚焦于解决**挑战一: 观测数据的选择偏差导致的增益效应估计偏倚**。

另一方面, 工业界对增益模型的应用是希望模型能够识别出那些 “只有在收到优惠券时才会购买” 的摇摆用户, 而非那些 “无论是否收到优惠券都会购买” 的忠诚用户, 从而在有限的预算下最大化总转化率, 因此模型针对用户的增益效益的排序能力至关重要。主流增益模型大多仍采用最小均方误差 (MSE) 等回归损失作为优化目标, 并未直接针对排序指标进行优化。加之金融、电商数据普遍呈现显著的长尾分布, 基于回归损失的模型极易过度关注极少数高增益的离群点, 而忽视了对绝大多数普通用户之间相对次序的有效学习, 这种排序能力的缺失, 直接导致了在有限预算下资源分配的错位。这就是增益模型当前研究存在的排序学习缺失问题。

增益模型的最终业务目标通常是根据预测的增益分数对用户进行排序, 以便截取 Top-K 的高价值用户进行投放。然而, 目前针对增益模型的研究主要集中在基于元学习器 (Meta-Learner) 的间接估计范式和基于表征学习 (Representation Learning) 的直接建模范式。元学习器方法 (如 S-Learner, T-Learner, X-Learner)^[11] 侧重于利用现有的强监督模型组合来近似增益效应, 其优化目标通常局限于最小化均方误差 (MSE) 等拟合指标, 缺乏对增益排序能力的显式建模。同样, 基于表征学习的方法 (如 TarNet, CFR-Net)^[5,9] 虽然尝试通过深度网络学习平衡表征来消除混淆, 但其损失函数设计依然以事实与反事实结果的拟合精度为导向, 忽视了排序指标 (如 AUUC) 与拟合指标之间的非一致性^[12]。从数学角度看, MSE 关注的是点估计的绝对精度, 而排序关注的是样本间的相对次序。这种 “训




图 1.4 排序学习缺失引发的排序错位示意图

练目标”与“应用目标”的错位，严重限制了模型在实际业务场景中的转化效果。在金融风控、电商促销等真实场景中，增益分布往往呈现极度的长尾特性与极端值干扰，极少数高敏感用户的增益值可能非常高。在基于梯度的优化过程中，这些稀疏的极端值会产生巨大的梯度，主导模型的更新方向。这导致模型过度关注这些“偶然性”或“噪声性”的极端样本，而忽视了对占据数据主体的普通用户的排序规律的学习。这种过拟合现象不仅降低了模型的泛化能力，还可能导致模型在测试集上的排序性能大幅下降。因此，深入研究增益模型的排序优化机制，对于构建高效、可信的智能营销系统具有重要的理论价值与现实意义。基于此，本研究致力于解决**挑战二：排序学习的缺失导致的增益排序性能受限**。

综上所述，深入探究增益模型中选择偏差与排序学习的问题，对于提升增益模型的理论深度与应用广度具有不可替代的重要意义。一方面，选择偏差的有效消除是确保因果推断结论可靠性的基石，只有在去偏的特征空间中，模型

才能捕捉到真正的增量信号，而非虚假的相关性；另一方面，增益模型的排序能力直接决定了增益模型在实际业务中的核心价值，即在有限预算下实现资源的最优配置。只有同时攻克这两大难题，才能构建出既具备统计学严谨性，又能适应复杂工业环境的高效智能决策系统。

本文聚焦于解决增益模型中的选择偏差与排序学习问题，旨在探索并提出一系列基于分布对齐与排序学习的理论和技术手段，以克服现有方法的局限。通过深入分析和解决这些问题，本研究不仅有助于提升增益效应估计的准确性与营销投放的投资回报率，还能够在实际应用中为企业决策提供更加科学、精准的指导。更重要的是，它为构建更加高效、智能的数字经济技术底座提供了坚实的理论基础和技术支持，从而推动智能营销乃至整个因果推断领域的可持续发展。

1.2 研究内容与贡献

对于基于观测数据的增益模型算法，本文在充分调研了国内外相关研究的现状以及不足之后，聚焦于以下两大核心挑战：

挑战一：观测数据的选择偏差导致的增益效应估计偏倚。由于干预分配的非随机性，干预组与对照组的特征分布存在显著差异，导致增益效应的估计混杂了用户自身的固有属性偏差，使得模型难以准确剥离出干预带来的真实增量。

挑战二：排序学习的缺失导致的增益排序性能受限。现有方法多关注拟合精度（如 MSE）而非排序能力，这种训练目标与业务决策目标的错位，导致模型在识别高价值用户时的排序性能不足。

针对上述问题，鉴于观测数据中严重的样本选择偏差会导致反事实预测的泛化能力下降，且现有的排序精度缺失使得营销资源难以触达真正敏感的用户群体，本文的研究目标是**设计一种融合分布对齐与排序学习的统一框架，旨在应对观测数据的选择偏差与排序学习缺失带来的挑战，从而构建一个更鲁棒、更精准的增益模型架构**。具体而言，本文在第三章中，通过引入最优传输理论中的 Sinkhorn 算法来最小化干预组与对照组的分布差异，解决选择偏差问题^[13-15]，并创新性地提出了样本密度加权的排序损失函数，以直接优化增益排序能力并

克服长尾分布的干扰，从而构建了“基于 Sinkhorn 与样本密度排序的增益模型框架”。进一步地，在第三章的研究基础上，第四章针对 Sinkhorn 算法仅考虑特征空间对齐而忽视结构信息的局限性，引入了融合 Gromov-Wasserstein 最优传输 (FGW-OT) 以实现更深层次的结构化对齐；同时，为了解决分布对齐、增益效应拟合与排序学习多任务之间的梯度冲突问题，引入了 GradNorm 动态多目标优化策略，实现了三者的协同提升，最终提出了“GradNorm 增强的结构化密度排序增益模型”，不仅在理论上完善了增益模型的优化框架，更在实际应用中显著提升了营销决策的精准度与鲁棒性。具体来说：

基于 Sinkhorn 与样本密度排序的增益模型：利用最优传输理论在特征层面消除干预组与对照组之间的分布差异，同时优化增益排序能力。在观测数据中，干预组与对照组的特征分布往往不一致，导致严重的混淆偏差，现有的元学习器方法难以有效处理这一问题。因此，本方法旨在引入 Sinkhorn 算法，通过度量并最小化两组样本表征分布间的 Wasserstein 距离，实现特征层面的分布平衡。此外，真实场景下增益分布呈现显著的长尾特性，稀疏的高价值样本往往产生极大的梯度从而主导优化过程，导致模型在占据绝大多数的主体人群上排序失效。为了缓解这一问题，本方法设计了密度加权的成对排序损失，通过高斯核函数估计样本密度并引入加权机制，降低稀疏长尾样本的权重干扰，使模型更加聚焦于主体样本的排序优化。综上所述，本文第三章提出的基于 Sinkhorn 与样本密度排序的增益模型的主要贡献可总结为以下四点：

- 提出一种新颖的基于最优传输驱动与排序学习的增益模型算法，从“基于分布对齐的偏差消除”的角度，利用最优传输技术实现干预组与对照组的特征平衡，提升反事实预测的泛化能力，设计了显式的机遇样本密度加权的排序损失，有效提升模型的排序能力。
- 引入 Sinkhorn 算法度量并最小化 Wasserstein 距离，在特征空间强制拉近干预组与对照组的分布，有效消除选择偏差。（解决挑战一）
- 设计基于样本密度加权的排序损失函数，利用高斯核密度估计实施“关注主体排序”的加权策略，有效解决了稀疏极值样本主导优化的问题，显著提升了模型在全局范围内的排序鲁棒性。（解决挑战二）

- 在三项公开基准数据集上进行了广泛实验，实验结果验证了该基础框架的有效性。相比于现有的基准模型，该方法在 PEHE、ATE、AUUC、AUQC 等核心指标上取得了显著提升。

GradNorm 增强的结构化排序增益模型：在基础对齐的同时考虑特征间的几何结构信息，并通过动态多目标优化保障排序精度的持续提升。首先，基础的 Sinkhorn 算法仅考虑了特征点对点的距离，忽略了特征空间内部的几何结构信息（如流形结构），导致去偏不彻底。因此，本方法引入 Fused Gromov-Wasserstein (FGW) 距离，在对齐特征分布的同时保留特征间的几何结构信息，实现更深层次的结构化去偏。此外，在引入复杂的 FGW 结构对齐后，强力的对齐约束往往产生主导性的梯度，导致模型忽视了对排序精度的优化，使得排序损失难以有效下降。因此，本方法引入 GradNorm 动态加权策略，根据各任务的梯度范数实时调整权重，确保排序目标在训练过程中不被“淹没”，从而在多任务竞争中实现排序精度的最大化。综上所述，本文第四章提出的 GradNorm 增强的结构化密度排序增益模型框架的主要贡献可总结为以下四点：

- 提出一个的基于 FGW-OT 与 GradNorm 的增益模型算法，从“结构化对齐”与“排序学习鲁棒性”的角度，进一步提升模型的去偏能力与排序性能。
- 引入 Fused Gromov-Wasserstein (FGW) 距离替代基础的 Wasserstein 距离，同时考虑特征分布与几何结构的对齐，实现更精细的结构化去偏。（**解决挑战一**）
- 引入 GradNorm 动态加权算法，解决因强力对齐约束导致的排序目标梯度被抑制的问题，确保模型能够持续、有效地优化排序指标，从而显著提升最终的排序精度。（**解决挑战二**）
- 在三项公开基准数据集上进行了大量实验，实验结果验证了进阶框架的有效性。该模型不仅优于现有的前沿基准模型，同时相较于第三章提出的基础框架，在多个指标上均表现出更优的性能。

总体而言，本文针对增益模型面临的观测数据分布偏差与排序学习的缺失这两大核心挑战，递进式地提出了两个创新框架。首先，提出了基于 Sinkhorn 与样本密度排序的增益模型框架（SDR），利用 Sinkhorn 算法实现特征层面的分布

对齐以消除增益效应估计偏倚，并设计密度加权排序损失以直接优化增益排序能力；在此基础上，为了克服 SDR 忽略几何结构及多任务冲突的局限，进一步提出了 GradNorm 增强的结构化排序增益模型 (GSDR)，通过引入 FGW 距离实现更深层次的结构化去偏，并利用动态多目标优化策略确保排序目标得到有效优化，从而在保证去偏效果的同时显著提升模型的排序性能。实验结果显示，本文提出的方法在解决选择偏差与提升模型排序能力上具备显著优势，能够更为有效地提升营销投放的 ROI。

1.3 本文的组织结构

本文对基于分布对齐与排序学习的增益模型算法展开研究，如图 1.5 所示，本文共有五个章节：

第一章，绪论。本章首先介绍了本文的研究背景、研究意义及当前增益模型面临的挑战，随后详细阐述了本文的主要研究内容和创新性贡献，最后概述了本文各个章节的组织结构。

第二章是研究现状和预备知识。本章全面回顾了增益模型的研究现状，涵盖了基于元学习器的间接估计方法、基于树模型的直接建模方法和基于表征学习的直接建模方法，并深入分析了现有方法在处理选择偏差和排序优化方面现有的研究成果与不足。

第三章详细阐述基于 Sinkhorn 与样本密度排序的增益模型与评估方法。首先介绍了该研究视角的背景与意义，接下来对增益模型中的因果推断问题及符号进行了形式化定义。然后详细描述了所提出的框架整体架构，重点阐述了基于 Sinkhorn 算法的特征对齐模块以及密度加权的排序损失函数。之后，针对公开基准数据集进行了详尽的实验，并对实验结果和关键参数进行了深入分析和讨论，结果证明了本章所提出的基础框架在消除选择偏差和提升排序性能方面的有效性。

第四章在第三章研究的基础上，分析 SDR 框架的局限性，提出了 GradNorm 增强的结构化排序增益模型。首先分析了基础框架在处理特征几何结构和多目标




图 1.5 本文的组织结构示意图

协同方面存在的不足，之后详细讲解了模型中的核心模块设计，包括引入 Fused Gromov-Wasserstein (FGW) 距离实现结构化对齐，以及利用 GradNorm 算法实现多目标动态加权。在最后针对实验结果和模型参数进行了消融实验和数据分析，结果表明该进阶框架相较于基准模型和基础框架均取得了显著的性能提升，充分证明了其在解决深层结构偏差与优化冲突问题上的优越性。

第五章是总结与展望。本章首先对全文的研究工作以及关键贡献做了系统性的总结概括，随后客观分析了当前研究中存在的不足之处，最后对增益模型领域未来可能的一些研究方向进行了展望。

第2章 研究现状和预备知识

增益模型 (Uplift Modeling) 中的选择偏差 (Selection Bias) 与排序学习 (Learning To Rank) 问题, 构成了因果推断在营销决策与个性化干预领域的核心挑战。这一问题不仅继承了传统反事实推断中因果效应识别的内在困难, 更因实际业务场景对资源分配效率与干预精准度的极高要求而呈现出独特的复杂性。随着增益模型在精准营销、用户增长及策略优化等领域的广泛应用, 模型的去偏能力与排序性能已成为决定干预策略投资回报率 (ROI) 及用户体验的关键因素。

鉴于此, 如图 2.1 所示, 本文旨在从选择偏差处理与排序优化两个维度系统梳理相关研究进展。首先, 本文全面回顾了增益模型领域的技术演进脉络, 涵盖了基于元学习器的间接估计范式、基于树模型方法的直接建模方法、以及近年来兴起的基于因果表征学习的直接建模方法, 并剖析了现有方法在应对选择偏差及排序优化任务时的局限性。其次, 本文重点探讨了解决选择偏差的经典理论框架, 并进一步分析了针对排序精度提升的研究现状及存在的技术瓶颈, 从而阐明本文研究在提升增益模型排序性能方面的理论意义与应用价值。

增益模型 (Uplift Modeling), 旨在通过对用户在不同干预下的潜在结果进行建模, 学习干预措施对个体行为产生的影响, 即因果效应。通过挖掘这种因果效应, 增益模型模型能够更准确地捕捉用户对营销活动的敏感度, 从而帮助决策者识别出那些真正能够被干预“说服”的用户群体, 实现营销资源的精准投放和投资回报率 (ROI) 的最大化。

从历史发展的角度来看, 增益模型的概念最早可以追溯到 Radcliffe 和 Surry 在 1999 年提出的“差分响应模型”^[4]。在早期的营销实践中, 业界主要关注响应模型 (Response Model), 即预测用户购买的可能性。然而, 这种方法无法区分“无论是否干预都会购买”的自然转化用户 (Sure Things) 和“只有干预才购买”的被说服用户 (Persuadables)。为了解决这一资源浪费问题, 增益模型应运而生, 它通过直接建模干预带来的增量价值, 填补了传统预测模型与因果决策之间的空白^[16,17]。随着因果推断理论 (如 Rubin 潜在结果框架) 与机器学习技术的深




图 2.1 本章节的研究框架

度融合，增益模型逐渐从简单的差分统计发展为包含树模型、元学习器和深度表征学习的完善技术体系^[18-22]。

2.1 增益模型的研究现状

本节总结概述了在增益模型方向上已有工作的研究现状及发展历程。根据建模思路的不同，将现有工作主要分为三大类^[23]：基于元学习器的间接估计方法、基于树模型的直接建模方法和基于表征学习的直接建模方法。接下来将逐一介绍每个类别的工作，并分析它们的适用场景以及优缺点。

2.1.1 因果推断与增益模型

增益模型的核心目标是评估干预措施对个体的增量影响，这本质上是一个因果推断问题。传统的预测模型关注的是相关性，即给定特征和干预下结果的条件概率；而增益模型关注的是因果性，即改变干预状态会导致结果发生多大的变化。本节基于鲁宾潜在结果框架来阐述增益模型的理论基础。

根据鲁宾潜在结果框架，对于每个用户，假设存在两个潜在结果：用户接受干预时的潜在结果 $Y(1)$ ，以及用户未接受干预时的潜在结果 $Y(0)$ 。这里的干预通常指营销活动中的发券、投放广告等操作。

因果效应定义为干预对结果的增量改变。对于特定个体，其个体处理效应 (Individual Treatment Effect, ITE) 定义为两个潜在结果之差：

$$\tau_i = Y_i(1) - Y_i(0). \quad (2.1)$$

然而，在现实世界中，我们无法同时观测到同一个体在接受干预和未接受干预下的结果。对于每个个体，我们只能观测到其中一种结果。这种无法同时获取两个潜在结果的现象被称为因果推断的根本问题。为了解决因果推断的根本问题，我们通常关注群体层面的统计量。平均处理效应 (Average Treatment Effect, ATE) 衡量的是干预对整个群体的平均影响，即 $\mathbb{E}[Y(1) - Y(0)]$ 。但在精细化运营场景中，我们更关心不同特征用户对干预的异质性反应。因此，增益模型的目标是估计条件平均处理效应 (Conditional Average Treatment Effect, CATE)，在增益模型的研究中也称之为条件增益效应，即给定用户特征 $X = x$ 下的平均增益效应：

$$\tau(x) = \mathbb{E}[Y(1) - Y(0)|X = x]. \quad (2.2)$$

通过估计 $\tau(x)$ ，我们可以根据用户的特征来预测其对干预的敏感度，从而制定个性化的决策策略。

增益模型本质上是因果推断在营销和个性化决策领域的具体应用。传统的预测模型即响应模型关注的是相关性，能够告诉我们“在这个特征和干预下，用户购买的概率是多少”，但无法回答“如果改变干预，购买概率会增加多少”。相比之下，增益模型即增益模型关注的是因果性，即估计干预操作带来的净增量。通过引入因果推断的理论框架，增益模型试图消除数据中的混淆偏差，从而识别出干预措施带来的真实增量价值。具体而言，因果推断为增益模型提供了两个关键支撑：

- **反事实推理能力**：通过构建反事实结果即用户未观测到的潜在结果，增益

模型能够评估“如果不进行干预会发生什么”，从而计算出真实的增益。

- **去偏机制**：观测数据通常存在选择偏差，例如发券往往针对活跃用户。因果推断中的倾向性得分、平衡表征等技术，使得增益模型能够从有偏数据中学习到无偏的因果效应。

2.1.2 基于元学习器的间接估计方法

基于元学习器的方法旨在利用现有的成熟预测模型（如随机森林、XGBoost、神经网络等）作为基础学习器（Base Learner），通过组合这些基础学习器的预测结果来间接推断个体的因果效应（Individual Treatment Effect, ITE）。这类方法通常具有较强的通用性和易用性。

T-Learner^[11]是最直观的一种元学习器框架。它将数据集按照干预状态分为干预组（Treatment Group）和对照组（Control Group）两部分，并分别在两组数据上训练两个独立的预测模型。其中一个模型用于预测用户接受干预后的结果 $\mu_1(x) = \mathbb{E}[Y|X = x, T = 1]$ ，另一个模型用于预测用户未接受干预时的结果 $\mu_0(x) = \mathbb{E}[Y|X = x, T = 0]$ 。这两个模型分别学习在给定用户特征和特定干预状态下的期望结果。最终的 Uplift 分数即为两个模型预测值之差：

$$\hat{\tau}_T(x) = \hat{\mu}_1(x) - \hat{\mu}_0(x). \quad (2.3)$$

尽管 T-Learner 实现简单且可以使用任意监督学习模型，但其缺点也十分明显：由于两个模型是独立训练的，它们之间的误差可能会相互累积。特别是在干预效应较弱（即干预组和对照组的期望结果非常接近）的情况下，两个模型的预测误差可能会完全淹没真实的增益信号，导致估计结果不稳定。此外，T-Learner 没有利用两组数据的共有信息，在样本量较少时容易过拟合。

为了解决 T-Learner 中两个模型独立训练导致的数据利用率不足问题，S-Learner^[11]提出将干预变量（Treatment Indicator）作为一个普通特征输入到单个模型中进行训练。模型学习到的映射函数用于拟合观测结果 $\mu(x, t) = \mathbb{E}[Y|X =$

$x, T = t]$ 。在预测阶段，分别将干预变量设为干预状态和对照状态代入模型，计算两者的差值作为增益效应估计：

$$\hat{\tau}_S(x) = \hat{\mu}(x, 1) - \hat{\mu}(x, 0). \quad (2.4)$$

S-Learner 能够充分利用所有数据进行训练，避免了样本量较小的组数据不足的问题。然而，S-Learner 也存在局限性：当干预特征的重要性远低于其他用户特征时，模型可能会倾向于忽略干预变量（即模型认为干预对结果的贡献很小），导致预测出的增益值趋近于零（Zero-Bias），无法有效捕捉干预带来的异质性效应。

针对 T-Learner 和 S-Learner 的不足，Künzel 等人提出了 X-Learner^[11]。该方法分三个阶段进行：第一阶段，像 T-Learner 一样，分别在干预组和对照组上训练两个基础模型 $\hat{\mu}_1(x)$ 和 $\hat{\mu}_0(x)$ 。第二阶段，利用这两个基础模型计算每个样本的“伪干预效应”（Imputed Treatment Effect）。对于干预组样本，计算其观测结果减去对照组模型的预测结果；对于对照组样本，计算干预组模型的预测结果减去其观测结果：

$$\begin{aligned} \tilde{D}_1 &= Y - \hat{\mu}_0(X), \quad \text{if } T = 1, \\ \tilde{D}_0 &= \hat{\mu}_1(X) - Y, \quad \text{if } T = 0. \end{aligned} \quad (2.5)$$

第三阶段，训练另外两个模型 $\hat{\tau}_1(x)$ 和 $\hat{\tau}_0(x)$ 来分别拟合这两组伪干预效应 $\tilde{D}_1$ 和 $\tilde{D}_0$ 。最终的增益效益估计是这两个模型的加权平均，权重通常由倾向性得分 $e(x)$ 决定：

$$\hat{\tau}_X(x) = e(x)\hat{\tau}_0(x) + (1 - e(x))\hat{\tau}_1(x). \quad (2.6)$$

X-Learner 特别适用于干预组与对照组样本量极度不平衡的场景，并且在处理结构化异质性效应时表现出色。但其多阶段的训练过程较为繁琐，且计算开销相对较大。

2.1.3 基于树模型的直接建模方法

传统的分类或回归树旨在通过最大化信息增益来降低预测的不确定性。然而,增益模型的目标是最大化干预组与对照组的分布差异。因此,基于树模型的方法主要集中在分裂准则 (Splitting Criteria) 的改进与集成学习策略上。

R.Forest^[24] 是一种基于随机森林模型的变体,其核心策略是将干预状态 (Treatment Status) 直接作为一个输入特征纳入模型训练中。通过这种方式,模型能够在构建树的过程中同时学习协变量与干预变量之间的交互关系,从而捕捉潜在的干预效应。与传统的独立建模方法不同, R.Forest 允许模型自适应地根据干预变量进行分裂,从而更灵活地识别出对干预敏感的子群体。这种简单而有效的设计使得 R.Forest 在处理异质性因果效应时具有较好的表现,同时也保留了随机森林模型本身的高效性和稳定性。

Orthogonal Forest (O.Forest)^[24] 是基于随机森林框架的一种改进方法,旨在通过引入正交化技术 (Orthogonalization) 来纠正潜在的混淆偏差,从而产生更可靠的因果效应估计。O.Forest 的核心思想是将因果效应估计分为两个阶段:首先,利用去偏技术去除混淆变量对结果和干预分配的影响 (即正交化过程);然后,在去偏后的残差上构建森林模型来估计条件平均处理效应 (CATE)。这种方法不仅保留了随机森林在处理非线性关系和高维数据方面的优势,还显著提升了因果推断的鲁棒性,特别是在存在复杂混淆因素的观测数据中表现出色。

Wager 和 Athey 提出的因果森林 (Causal Forest^[24]) 是基于随机森林的非参数因果推断方法。其将样本分为两部分,一部分用于生成树结构,另一部分用于估计叶子节点的因果效应,从而保证了估计量的渐近正态性。Causal Forest 不仅能够估计异质性因果效应 (CATE),还能给出估计的置信区间,具有坚实的统计学理论基础。

2.1.4 基于因果表征学习的深度建模方法

与元学习器不同,基于表征学习的方法试图通过深度学习技术 (如变分自编码器^[25,26]、ESMM^[27]、AutoConjunction^[28]、Conformity Modeling^[29] 等),将因




图 2.2 基于因果表征学习的模型架构

果推断中的核心假设（如无混淆假设）融入到模型的特征提取过程中。这类方法通常采用端到端的训练方式，旨在学习到一个平衡的特征表示空间，从而直接消除选择偏差并提升增益模型预测的准确性。

Shalit 等人提出的 TarNet (Treatment-Agnostic Representation Network)^[5] 是该领域的奠基性工作之一。如图 4.3 (a) 所示, 该模型采用这种多头网络结构 (Multi-headed Architecture), 首先通过一个共享的特征提取网络 $\Phi(x)$ 学习数据的公共表征, 然后分别连接两个独立的预测头 (Hypothesis Layers) 来估计干预组结果 $h_1(\Phi(x))$ 和对照组结果 $h_0(\Phi(x))$ 。这种结构既利用了所有样本来学习共享特征, 又保留了干预组与对照组的特异性, 避免了简单拼接干预变量导致的干预信息丢失问题^[30]。其损失函数为标准的均方误差 (MSE):

$$\mathcal{L}_{TarNet} = \frac{1}{n} \sum_{i=1}^n (y_i - h_{t_i}(\Phi(x_i)))^2. \quad (2.7)$$

虽然 TarNet 解决了多头预测的问题, 但它并没有显式地处理选择偏差。为此, Shalit 等人在 TarNet 的基础上引入了平衡正则化项, 提出了 CFR-Net (Counterfactual Regression Network)^[5]。如图 4.3 (b) 所示, 该模型在损失函数中增加了一个分布差异惩罚项 (Integral Probability Metric, IPM), 强制要求干预组和对照组在共享表征空间 $\Phi(x)$ 中的分布尽可能一致。常用的 IPM 度量包括最大均值差异 (MMD)^[31] 和 Wasserstein 距离^[32]。通过最小化 $W(\Phi(X)_{t=1}, \Phi(X)_{t=0})$, CFR-Net 能够学习到一种“平衡表征”, 使得模型在反事实预测时的泛化误差上

界更低。其优化目标为：

$$\mathcal{L}_{CFR} = \mathcal{L}_{TarNet} + \alpha \cdot \text{IPM}(\{\Phi(x_i)\}_{i:t_i=1}, \{\Phi(x_i)\}_{i:t_i=0}), \quad (2.8)$$

其中 α 是控制平衡强度的超参数。

为了进一步利用干预分配机制中的信息，Shi 等人提出了 Dragonnet^[33]。该模型认为，导致选择偏差的混淆因子（Confounders）通常与干预分配概率（倾向性得分）高度相关。因此，Dragonnet 在共享表征层之后增加了一个倾向性得分预测头（Propensity Head），通过多任务学习的方式同时预测结果 Y 和干预概率 T 。这种设计迫使共享表征层 $\Phi(x)$ 更加关注那些既影响结果又影响干预分配的混淆变量，从而实现更有效的去偏。此外，Dragonnet 还提出了一种基于目标正则化的估计方法（Targeted Regularization），进一步提升了 CATE 估计的鲁棒性。其总损失函数包含预测误差和倾向性得分误差：

$$\mathcal{L}_{Dragonnet} = \mathcal{L}_{TarNet} + \beta \cdot \text{CrossEntropy}(t_i, \hat{g}(\Phi(x_i))), \quad (2.9)$$

其中 $\hat{g}(\cdot)$ 是倾向性得分预测网络， β 是权重系数。

尽管这些基于表征学习的方法在消除选择偏差方面取得了显著进展，但它们大多只关注特征分布的边缘对齐，往往忽略了特征空间内部的几何结构信息，且在面对复杂的排序优化目标时，缺乏专门的设计。

2.1.5 增益模型评估指标

由于我们无法观测到真实的反事实结果（即无法同时知道同一个用户在干预和不干预下的表现），增益模型的评估比传统预测模型更为复杂。我们不能简单地使用 PEHE、ATE 等指标。常用的评估指标主要基于 Uplift 曲线（Uplift Curve）和 Qini 曲线（Qini Curve）^[4]。Uplift 曲线是通过将测试集用户按照预测的 Uplift 分数从高到低排序，然后计算累积增益来构建的。假设我们将用户按分

数排序后分为 K 份（例如 10 份），对于前 k 份用户，计算其累积增益：

$$Uplift(k) = \left(\frac{Y_t^k}{N_t^k} - \frac{Y_c^k}{N_c^k} \right) (N_t^k + N_c^k), \quad (2.10)$$

其中 Y_t^k, Y_c^k 分别表示前 k 份用户中干预组和对照组的转化人数， N_t^k, N_c^k 分别为对应的人数。AUUC (Area Under Uplift Curve) 即为 Uplift 曲线下的面积。AUUC 越大，说明模型将高增益用户排在前面的能力越强。

Qini 曲线是另一种广泛使用的评估指标，它是 Uplift 曲线的一个变体，对各组样本量的不平衡更为鲁棒。Qini 曲线的累积增益定义为：

$$Qini(k) = Y_t^k - Y_c^k \frac{N_t}{N_c}. \quad (2.11)$$

Qini 系数 (Qini Coefficient) 则是 Qini 曲线下的面积与随机模型曲线下面积之差，再除以理想模型 (Optimal Model) 与随机模型之间的面积差。这些指标不仅评估了模型的排序能力，也直接反映了在有限营销预算下，按照模型排序进行投放所能带来的实际业务增量。

2.1.6 现有研究的不足与挑战

尽管上述增益模型方法在理论完善与实践应用方面均取得了显著进展，但在面对复杂的真实业务场景时，仍存在若干关键局限性，特别是在处理观测数据的选择偏差与满足业务导向的排序需求方面。

首先，**观测数据中普遍存在的选择偏差 (Selection Bias) 严重影响了因果效应估计的准确性**。在实际的业务场景中，由于运营策略的倾向性（例如，优惠券通常发放给高活跃度或高消费意愿的用户），干预组与对照组的样本分布往往存在显著的系统性差异。这种非随机化的干预分配破坏了因果推断中的同质性假设，导致“相关性”不等于“因果性”。若模型无法有效解耦这种由混淆变量 (Confounders) 引入的虚假关联，就会产生严重的估计偏差，使得决策者难以区分业务指标的提升究竟是源于干预措施本身，还是仅仅因为触达了表现更好的

用户群体。这种偏差不仅会导致因果效应的错误估计，更会误导资源分配策略，造成营销预算的浪费。

其次，模型优化目标与决策目标存在错位，模型缺乏显式的排序学习机制。增益模型的最终落地形式通常是预测的增益值对用户进行排序，以筛选出高潜用户进行干预。这意味着模型的排序能力（Rankability）远比具体的数值回归精度更为重要。然而，绝大多数现有的增益模型（包括 T-Learner、S-Learner 以及 TarNet 等）在训练时均采用均方误差（MSE）作为损失函数。MSE 旨在追求对个体处理效应（ITE）的点估计准确性，但这并不等同于最优的排序性能。回归误差最小化并不保证排序指标（如 AUUC 或 NDCG）最大化。现有的模型未能直接将排序目标融入训练过程，使得模型在区分“高增益”与“低增益”用户时往往显得力不从心，限制了其在精准营销资源分配中的实际效能。

综上所述，如何在深度表征学习的框架下，设计更精细的去偏机制以应对复杂的选择偏差，同时引入面向排序的优化目标以提升模型的决策能力，是当前增益模型领域亟待解决的核心问题。这也正是本文研究的切入点与主要贡献所在。

2.2 选择偏差问题及其研究现状

2.2.1 选择偏差的来源与定义

在理想的随机对照试验（Randomized Controlled Trial, RCT）中，干预分配机制是完全随机的，即用户是否接受干预（如是否收到优惠券）与其自身的特征（如历史购买金额、活跃度等）无关。这保证了干预组（Treatment Group）和对照组（Control Group）在协变量分布上是同质的，即 $P(X|T=1) \approx P(X|T=0)$ 。在此条件下，两组观测结果的差异可以直接归因为干预本身的影响，即“相关性”等同于“因果性”。

然而，在实际的观测数据中，干预分配往往是非随机的，受到特定策略或用户自主选择的影响。例如，在营销活动中，运营人员倾向于给活跃度高、消费意愿强的用户发放优惠券；在医疗场景中，医生倾向于给病情较重的患者开具特

定药物。这种非随机的分配机制导致干预组和对照组在特征分布上存在显著差异，即 $P(X|T=1) \neq P(X|T=0)$ 。这种现象被称为选择偏差（Selection Bias）。

选择偏差的存在使得直接比较两组的平均结果会产生有偏的因果效应估计。形式化地，假设 Y 为观测结果， T 为干预变量， X 为混淆变量（既影响干预分配又影响结果的变量）。若忽略选择偏差，直接计算平均处理效应（ATE）会引入偏差项：

$$\begin{aligned} \mathbb{E}[Y|T=1] - \mathbb{E}[Y|T=0] &= \underbrace{\mathbb{E}[Y(1) - Y(0)]}_{\text{ATE (真实因果效应)}} \\ &+ \underbrace{\{\mathbb{E}[Y(0)|T=1] - \mathbb{E}[Y(0)|T=0]\}}_{\text{Selection Bias (选择偏差)}}. \end{aligned} \quad (2.12)$$

其中，偏差项反映了在未接受干预的潜在状态下，干预组与对照组本身存在的固有差异。如果不能有效消除这一偏差，模型可能会错误地将这种固有差异归因为干预效果，从而误导决策。

2.2.2 解决选择偏差的研究现状

为了从有偏的观测数据中恢复出真实的因果效应，学术界提出了多种去偏方法^[34,35]，主要可归纳为三大类：基于重加权的方法、基于匹配的方法以及基于表征学习的方法。

基于重加权的方法旨在通过调整样本权重，使得加权后的处理组和对照组分布尽可能一致，从而模拟随机对照试验的条件。这类方法通过赋予不同样本以不同的统计权重来平衡协变量的不平衡性。

逆倾向评分（Inverse Propensity Score, IPS）^[36]方法是最基础且广泛应用的方法。它根据个体接受处理的估计概率（即倾向性评分 $e(x) = P(T=1|X=x)$ ）的倒数来分配权重：处理组权重为 $1/e(x)$ ，对照组权重为 $1/(1-e(x))$ 。这确保了那些接受处理概率较低的个体在分析中具有更大的贡献，从而拉平两组分布。然而，IPS方法存在数值不稳定性问题：当倾向性评分接近0或1时，权重会变得极大，导致估计方差剧增。

为了缓解这一问题,双重鲁棒方法(Doubly Robust Methods)结合了IPS与结果回归模型^[37-40]。只要倾向性评分模型或结果回归模型中有一个被正确设定,因果效应的估计就是一致的,这为模型错误假设提供了一层保障。近年来,学者们进一步提出了多种改进的双重鲁棒学习框架,如广义双重鲁棒学习^[41]、增强双重鲁棒学习^[42]、目标导向双重鲁棒学习^[43]以及稳定双重鲁棒学习^[44]等,以进一步提升模型在复杂场景下的鲁棒性。

此外,为了改善平衡性,Imai和Ratkovic提出了协变量平衡倾向评分(Covariate Balancing Propensity Score, CBPS)^[45],该方法在估计倾向性评分的同时直接优化协变量的平衡约束^[46]。Christian等人进一步引入了基于核的方法(Kernel-based techniques)来优化平衡度量^[47]。除了单纯依赖权重,Kuang等人提出了引入调整变量(Adjustment Variables)的方法,利用辅助协变量来优化加权函数,增强模型在混淆变量存在下的稳健性^[48,49]。

尽管重加权方法理论基础深厚,但它们严重依赖于“共同支撑(Common Support)”假设。在处理组和对照组重叠度较差(Poor Overlap)的情况下,极端权重的出现会导致估计结果极不稳定。

基于匹配的方法通过在处理组和对照组中寻找特征相似的个体配对,构建平衡的比较组。倾向性评分匹配(P propensity Score Matching, PSM)是其中的代表,它根据倾向性评分将不同组的个体进行配对。这种方法在计量经济学和医学研究中被广泛使用。然而,PSM存在明显的局限性:一是未匹配的样本会被丢弃,降低了统计效力;二是难以处理高维数据,在高维空间中寻找精确匹配的计算成本极高(即维数灾难)。

为了改进标准匹配,Chang等人引入了信息匹配(Informative Matching)^[50],结合领域知识来提升匹配质量。Li等人提出了更灵活的匹配框架^[51],优先考虑最小化残差偏差。此外,基于树的方法也被提出作为替代方案,例如Stefan等人提出的将决策树集成到匹配框架中的方法,允许基于干预异质性进行自适应分层。尽管如此,匹配方法在大规模数据集上的计算效率依然是一个瓶颈。

随着深度学习的发展,基于表征学习的方法逐渐成为主流。这类方法旨在学习一个低维的潜在表示空间,在该空间中,处理组和对照组的分布被强制对

齐，同时保留对结果预测有用的信息。

Johansson 等人提出的 Counterfactual Regression (CFR)^[9] 是该领域的开创性工作，它训练神经网络来学习平衡表征，通过最小化反事实预测误差来估计因果效应。Shalit 等人进一步扩展了该方法，提出了 CFR-MMD，在损失函数中引入最大均值差异 (Maximum Mean Discrepancy, MMD) 作为正则化项，以衡量并惩罚两组样本在潜在空间中的分布差异。尽管有效，CFR-MMD 在处理高维数据时可能面临挑战，且对核函数的选择较为敏感。

此后，多种扩展方法相继被提出。例如，DTANet^[52] 利用对抗域适应 (Adversarial Domain Adaptation) 技术，通过引入判别器使两组的潜在表示不可区分，从而实现更有效的知识迁移，尤其适用于分布偏移场景，但对抗训练往往存在优化不稳定的问题。BWCFR^[53] 采用双重加权框架，动态调整样本重要性，分别学习用于控制干预分配偏差和反事实结果估计的权重，以解决不平衡数据集下的高方差问题。ESCFR^[54] 引入基于熵的约束来保持表示空间的稳定性与公平性，防止潜在空间坍塌，确保少数子群体的充分表示，但引入了额外的计算开销和超参数。CE-RCFR^[55] 提出了因果效应正则化项，通过惩罚不同子群体间估计效应的变异来增强模型在分布偏移下的稳定性。StableCFR^[56] 则结合重加权和重采样策略，确保代表性不足的群体在训练中得到充分关注，从而提升 CATE 估计的鲁棒性。

总体而言，基于表征学习的方法相比传统方法具有更高的灵活性和泛化能力，能够更好地处理高维非线性数据，是当前增益模型研究的前沿方向。近年来，该领域涌现了大量结合因果推断与深度学习的创新工作，包括反事实评估与学习^[57]、数据增强序列推荐^[58]、因果表征学习^[59-61]、模型无关的因果学习^[62]、无偏推荐学习^[63]、反事实用户偏好模拟^[64]、点击诱饵缓解^[65]、流行度偏差消除^[66,67]、平衡未观测混淆^[68]、多重鲁棒学习^[69]、自动去偏^[70]、信息瓶颈去偏^[71]、对抗平衡训练^[72] 以及因果偏好学习^[73] 等。

2.3 排序精度问题及其研究现状

2.3.1 排序学习问题的来源与定义

在增益模型的实际应用中，尤其是在营销资源有限的场景下，决策者的核心需求往往不是精确预测每个用户的具体增益数值（Uplift Score），而是能够准确地识别出哪些用户的增益最高，从而优先对这些用户进行干预。例如，在预算只能覆盖前 10% 用户的营销活动中，模型只需确保前 10% 用户的平均增益最大化，而无需关心具体的预测值误差。这种需求使得增益模型在本质上更接近于一个排序问题，而非单纯的回归问题。

然而，绝大多数现有的增益模型（如 S-Learner, T-Learner, TarNet 等）在训练时均采用均方误差（MSE）作为损失函数。MSE 旨在最小化预测值与真实值之间的点对点误差（Pointwise Error）。正如信息检索领域的研究所揭示的，最小化回归误差并不等同于最大化排序指标（如 AUUC 或 AUQC）。这种优化目标（回归精度）与决策目标（排序精度）之间的错位（Misalignment），导致了排序学习问题的产生^[74,75]。

形式化地，增益模型中的排序学习问题可以定义为：寻找一个评分函数 $f(x)$ ，使得根据 $f(x)$ 排序后的用户列表在特定的累积增益指标（如 AUUC）上达到最大。若模型仅追求 $\sum (f(x) - \tau(x))^2$ 最小，可能会在对排序无关紧要的样本（如低增益区域）上过度拟合，而忽略了对高增益样本的相对顺序的保持。

2.3.2 排序学习研究现状

为了解决回归目标与排序目标不一致的问题，排序学习（Learning to Rank, LTR）作为一种专门的技术路线在近几十年中受到了广泛关注，并被部署在许多不同的应用中。根据输入空间和损失函数的不同，LTR 方法主要分为三类：单点法（Pointwise）、成对法（Pairwise）和列表法（Listwise）。

单点法：如 Mcrank 等方法最早被提出用于解决排序问题。这类方法将排序问题转化为对每个单个对象的回归或分类任务。模型被训练来预测一个对象对于给定查询的相关性分数。这种方法的核心问题在于其优化目标与原始排序任

务之间存在偏差，因为它只关注单个样本的绝对准确性，而忽略了样本之间的相对顺序关系^[76]。

成对法：作为一种替代方案，成对法将对象对（Object Pairs）纳入考虑，将排序问题转化为二分类任务。换句话说，模型需要判断每一对对象的相对顺序相对于真实情况（Ground Truth）是否错误。这一方向的代表性工作包括 RankSVM、Rankboost、RankNet、LambdaRank 和 LambdaMART。在实践中，成对法通常能取得比单点法更有希望的结果，因为它更接近排序的本质。然而，它们也存在一个显著的缺点，即忽略了不同对象对之间的差异性（Discrepancy），例如排在列表顶部的错误通常比排在底部的错误代价更大^[12]。

列表法：为了解决成对法的问题，Adarank、ListNet、ListMLE 等列表法被提出作为一种直接的解决方案^[77]。这类方法同时考虑所有对象，将整个列表作为输入进行优化，旨在直接最大化排序指标（如 NDCG）。

2.3.3 现有研究的局限性

尽管排序学习方法在信息检索任务（如文档检索）中已经相当成熟，但其在因果效应估计，特别是在线营销中的增益模型领域的应用几乎未被探索，这构成了本文研究的另一个重要动机，即探索如何将排序学习的思想引入增益模型以直接优化干预策略的排序精度。

2.4 本章小结

本章首先系统阐述了增益模型在精准营销与个性化决策领域的研究背景与理论基础，明确了其作为因果推断与机器学习交叉领域的重要地位。随后，从技术演进的角度，全面回顾了现有的增益模型方法，包括早期的基于树模型的直接建模范式、基于元学习器的间接估计范式，以及近年来兴起的基于因果表征学习的深度建模范式。在此基础上，本章重点剖析了当前研究面临的两大核心挑战：一是观测数据中普遍存在的选择偏差（Selection Bias），它严重干扰了因果效应的准确估计；二是传统回归优化目标与实际业务决策目标之间的错位，

导致模型的排序学习的不足。

针对上述不足，本文梳理了目前的研究现状，并总结了已有的研究成果。尽管现有的解决方案在一定程度上缓解了问题，但仍存在局限性。鉴于此，本文将针对选择偏差消除与排序学习的提升这两个关键问题展开深入研究。

第3章 基于 Sinkhorn 与样本密度排序的增益模型与评估办法

本章从“基于分布对齐与排序学习的增益模型”建模角度出发，聚焦于该领域现有方法存在的两个核心挑战：一方面，现有方法在高维特征空间中难以消除由非随机干预导致的选择偏差，限制了因果效应估计的泛化能力；另一方面，传统模型多侧重于最小化预测误差的数值拟合，往往忽视了对实际决策至关重要的增益排序能力的直接优化，且极易受长尾分布中稀疏极端值的干扰。为解决以上问题，本章提出了一个基于最优传输与样本密度排序的增益模型 SDR。该模型通过基于 Sinkhorn 的最优传输对齐模块实现干预组与对照组在特征层面的深度去偏，并利用密度加权的排序学习模块来解决长尾噪声干扰与排序目标缺失的问题，从而显著提升增益模型在反事实预测与精准营销排序上的综合性能。

3.1 引言

随着全球数字经济的蓬勃发展与互联网流量红利的逐渐消退，精细化运营已成为企业在存量时代提升核心竞争力的关键手段。在这一宏观背景下，如何精准识别高价值用户并制定差异化的营销策略，成为学术界与工业界共同关注的焦点。传统的营销模型多基于响应模型，其核心逻辑是预测用户在特定干预下的转化概率，即 $P(Y = 1|T = 1, X)$ 。然而这种建模方式存在显著的逻辑缺陷：它无法区分用户是因为“干预”而转化，还是因为“自身属性”而转化。例如，某些忠诚用户无论是否收到优惠券都会购买，对这类用户发放优惠券不仅无法带来增量收益，反而会造成营销预算的浪费。

为了解决这一问题，增益模型应运而生^[1,78]。作为因果推断在营销领域的落地应用，增益模型旨在量化干预措施对个体结果的增益效应，即条件平均增益效应（CATE）。通过准确估计 $\tau(x) = P(Y|T = 1, X) - P(Y|T = 0, X)$ ，增益模型能够帮助决策者识别出真正的“说服组”——即只有在接受干预后才会转化的用户。这使得企业能够在预算受限的情况下，最大化投资回报率 ROI，实现

真正的精准营销。

尽管增益模型具有巨大的应用潜力，但在基于观测数据进行建模时，也存在着严峻的挑战。这些挑战根植于因果推断的反事实性质以及真实数据分布的复杂性。

挑战一：高维复杂空间下的样本选择偏差导致模型对增益效应估计产生偏倚：在理想的随机对照试验 RCT^[56,79] 中，干预分配是随机的，满足 $T \perp X$ 。然而，在现实的观测数据^[9,80] 中，干预分配往往受到混淆变量的影响。例如，运营人员倾向于给活跃度高的用户发放红包，导致干预组用户的特征分布显著优于对照组（即 $P(X|T=1) \neq P(X|T=0)$ ）。这种分布偏移破坏了因果推断的“无混淆假设”，使得直接训练的模型学习到的是特征与结果的相关性，而非干预的因果效应。现有的去偏方法，如基于最大均值差异 MMD^[5,31] 或 Wasserstein 距离^[32]，在低维空间表现尚可。但在高维特征空间中，MMD 难以精确度量复杂的分布差异，而对抗训练则面临训练不稳定、梯度消失或模式崩溃等难题，难以在去偏与保留预测能力之间取得平衡。

挑战二：排序学习的缺失导致增益模型排序性能不足：增益模型的最终业务目标通常是根据预测的增益分数对用户进行排序，以便截取 Top-K 的高价值用户进行投放。然而，现有的主流方法大多基于回归框架，以最小化数值拟合误差（如 MSE）为优化目标，忽视了对样本间相对次序的直接优化。数值拟合得准并不意味着排序排得准，这种“训练目标”与“应用目标”的错位严重限制了模型的转化效果。此外，真实场景中的增益分布往往呈现极度的长尾特性。绝大多数用户的增益值接近于 0，而极少数高敏感用户的增益值极高。在基于梯度的优化过程中，这些稀疏的极端值往往产生巨大的梯度，主导模型的更新方向，导致模型过度关注偶然性极端样本，而忽视了对占据数据主体的普通用户的排序规律学习。这种排序能力的缺失与长尾干扰的叠加，使得模型难以在复杂的真实分布中实现精准的营销决策。

为了系统性地解决上述两大核心挑战，本章提出了一个**基于 Sinkhorn 与样本密度排序的增益模型**，简称 SDR。该框架创新性地将最优传输理论引入增益模型，利用 Wasserstein 距离优良的几何性质来解决高维分布对齐问题；同时，结

合排序学习思想，设计了密度加权的成对排序损失，在直接优化增益排序目标的同时，利用密度加权机制抑制长尾噪声的干扰。本章的主要贡献总结如下：

- **提出了基于 Sinkhorn 与样本密度排序的增益模型框架。**针对观测数据中的选择偏差与增益分布的长尾特性，本文构建了一个融合最优传输理论与排序学习的统一框架（SDR）。该框架创新性地将 Sinkhorn 算法与密度加权机制相结合，不仅在特征层面消除了干预组与对照组的分布差异，更在目标层面直接优化了增益排序能力，为精准营销提供了鲁棒的算法支撑。
- **引入 Wasserstein 距离进行因果去偏。**引入 Wasserstein 距离进行去偏。本研究将最优传输理论引入增益模型，利用 Sinkhorn 算法实现特征对齐任务。相比于传统的 KL 散度或 MMD，Wasserstein 距离具有优良的几何特性，特别是在处理高维空间中支撑集不重叠（Disjoint Support）的分布时，仍能提供有效的梯度信号。基于这一特性，我们在模型中构建了深度对齐机制，在高维特征空间中实现了更深层次、更鲁棒的分布拉齐，从而有效消除了选择偏差。
- **提出密度加权成对排序损失。**针对长尾分布问题，通过高斯核密度估计量化样本的稀疏程度，并设计了“基于样本密度的加权”机制。该机制在强化排序目标的同时，自适应地提升了高密度主体样本的权重，降低了稀疏噪声样本的干扰，有效解决了长尾分布中的噪声干扰问题，实现了对全域用户增益排序的精准优化。
- **全面深入的实验分析。**在公开基准数据集 MovieLens-100K、Hillstrom-Man、Hillstrom-Woman 上进行了广泛的实验。除了 PEHE、AUUC 和 AUQC 指标对比外，还深入进行了消融实验、超参数敏感性分析，验证 SDR 在处理选择偏差和排序优化方面的显著优势。

3.2 问题描述与定义

3.2.1 因果推断框架与假设

本章基于 Rubin 提出的潜在结果框架 (Rubin Causal Model)^[81], 来形式化增益模型问题。设 $\mathcal{U} = \{u_1, u_2, \dots, u_N\}$ 表示用户集合, 其中 N 为样本量。对于每个用户 u_i , 我们观测到三元组 $(\mathbf{x}_i, t_i, y_i^{obs})$:

- $\mathbf{x}_i \in \mathcal{X} \subseteq \mathbb{R}^d$: 表示用户的特征向量
- $t_i \in \{0, 1\}$: 表示干预指示变量。 $t_i = 1$ 表示接受干预, $t_i = 0$ 表示未接受干预
- $y_i^{obs} \in \mathbb{R}$: 表示用户的观测结果, 即实际的转化行为如购买金额、点击率。

根据潜在结果框架, 对于每个个体 u_i , 存在两个潜在结果即: 若用户 i 接受干预, 其潜在的结果为 $y_i(1)$; 若用户 i 未接受干预, 其潜在的结果为 $y_i(0)$ 。因果效应定义为这两个潜在结果的差值: $\tau_i = y_i(1) - y_i(0)$ 。然而, 在现实世界中, 我们面临“因果推断的根本问题”: 对于任意个体, 我们不可能同时观测到其接受干预和未接受干预的状态即反事实状态不可观测。我们只能观测到其中一种结果:

$$y_i^{obs} = t_i y_i(1) + (1 - t_i) y_i(0). \quad (3.1)$$

我们的目标是估计**条件平均处理效应** Conditional Average Treatment Effect, CATE, 即:

$$\tau(\mathbf{x}) = \mathbb{E}[y(1) - y(0)|\mathbf{x}] = \mathbb{E}[y(1)|\mathbf{x}] - \mathbb{E}[y(0)|\mathbf{x}]. \quad (3.2)$$

为了保证 CATE 是统计可识别的, 必须满足以下三个经典假设:

- **稳定单元处理值假设**: 包含两个子假设:
 - **无干扰**: 一个个体的潜在结果不受其他个体干预状态的影响。
 - **一致性**: 对于观测到的干预状态, 其潜在结果等于观测结果。
- **无混淆假设**: 给定特征 $\mathbf{x}$, 潜在结果与干预分配相互独立, 这是消除选择偏差的理论基础。
- **重叠假设**: 对于特征空间中的任意 $\mathbf{x}$, 个体接受干预和不接受干预的概率

都严格大于 0 且小于 1。

3.2.2 选择偏差的数学刻画

在观测数据中，无混淆假设往往难以直接满足。由于选择偏差的存在，干预组和对照组的特征分布不一致，即 $P(\mathbf{x}|t=1) \neq P(\mathbf{x}|t=0)$ 。这种分布差异会导致模型学习产生偏差。具体来说，如果我们直接训练一个模型 $f(\mathbf{x}, t)$ 来拟合 y^{obs} ，根据贝叶斯定理，模型拟合的期望为：

$$\mathbb{E}[y^{obs}|t, \mathbf{x}] = \int y \cdot P(y|t, \mathbf{x}) dy. \quad (3.3)$$

如果 t 与 $\mathbf{x}$ 强相关即存在选择偏差，模型倾向于利用特征 $\mathbf{x}$ 来预测 t ，进而利用 t 的分布信息来辅助预测 y 。这导致学到的效应 $\tau(\mathbf{x})$ 包含了特征与结果的虚假相关性，而非纯粹的因果效应。

例如，假设高消费用户特征 x_{high} 更倾向于被发券 $t=1$ ，且他们本身购买力就强 y 高。模型可能会错误地将高购买力归因于发券，从而高估干预效应。为了解决这一问题，我们需要寻找一个特征变换即表示学习 $\Phi(\mathbf{x})$ ，使得在变换后的隐空间 $\mathcal{Z}$ 中，分布差异被消除：

$$P(\Phi(\mathbf{x})|t=1) \approx P(\Phi(\mathbf{x})|t=0). \quad (3.4)$$

同时， $\Phi(\mathbf{x})$ 必须尽可能保留预测 y 所需的语义信息，即最小化因果效应预测的信息损失。这构成了本章 SDR 模型的核心设计思路。

3.2.3 排序精度与长尾干扰的数学刻画

增益模型的核心目标不仅在于精准估计个体的条件平均处理效应 (CATE)，更在于根据估计的增益值 $\hat{\tau}(\mathbf{x})$ 对用户进行排序，从而实现最优的资源分配。然而，现有的模型优化目标与实际业务需求之间存在显著的错位，且真实场景中的增益分布往往呈现长尾特性，这给排序精度的提升带来了双重挑战。

大多数现有的增益模型（如 S-Learner, T-Learner）采用均方误差（MSE）作为损失函数：

$$\mathcal{L}_{MSE} = \frac{1}{N} \sum_{i=1}^N (\hat{\tau}(\mathbf{x}_i) - \tau(\mathbf{x}_i))^2. \quad (3.5)$$

然而，MSE 关注的是数值估计的绝对误差，而业务决策关注的是样本间的相对顺序。考虑两个模型 f_1 和 f_2 ，若 f_1 对所有样本的预测值均偏高一个常数 C ，即 $\hat{\tau}_1(\mathbf{x}) = \tau(\mathbf{x}) + C$ ，则其 MSE 很大，但其诱导的排序是完美的；反之，若 f_2 在数值上拟合较好但在关键样本对的相对顺序上发生错误，则其 MSE 较小但排序性能（如 AUUC）较差。这种“数值拟合”与“相对排序”的不一致性，导致直接优化 MSE 并不一定能带来最优的营销效果。

在实际营销场景中，用户的增益分布通常呈现显著的长尾（Long-Tail）特征^[82]：存在极少数高敏感用户的增益值非常大，长尾分布意味着：在基于梯度的优化过程中，这些处于尾部的高敏感样本往往会产生巨大的梯度信号 $\nabla_{\theta} \mathcal{L}$ ，其模长远大于主体样本的梯度。这导致模型的参数更新方向被少数极端值主导，而忽视了对占据数据主体的普通用户的排序规律学习。这种过拟合现象不仅降低了模型的鲁棒性，还可能导致模型在面对分布略有偏移的测试集时，排序性能大幅下降。因此，如何设计一种机制，既能捕捉高价值信号，又能抑制长尾噪声的干扰，是提升增益排序精度的关键。

3.2.4 符号定义

为了清晰地描述本章提出的模型框架与算法细节，本节将对文中涉及的核心数学符号进行统一定义。

本章定义 $\mathcal{U} = u_1, u_2, \dots, u_N$ 表示包含 N 个样本的用户集合。对于任意用户 $u_i \in \mathcal{U}$ ，其观测数据表示为三元组 $(\mathbf{x}_i, t_i, y_i^{obs})$ 。其中， $\mathbf{x}_i \in \mathbb{R}^d$ 代表用户 i 的 d 维特征向量，包含历史行为与人口统计学属性等混淆变量； $t_i \in \{0, 1\}$ 为二值干预指示变量， $t_i = 1$ 表示该用户属于干预组（Treatment Group）， $t_i = 0$ 表示该用户属于对照组（Control Group）； $y_i^{obs} \in \mathbb{R}$ 则表示观测到的实际转化结果。

在潜在结果框架下，定义 $y_i(1)$ 和 $y_i(0)$ 分别为用户 i 在接受与未接受干预时

的潜在结果。本章的核心预测目标是条件平均处理效应 (CATE)，即增益分数，记为 $\tau(\mathbf{x})$ 。

在模型架构层面，定义 $\Phi(\cdot)$ 为共享特征提取器，将原始特征映射为隐空间表征 $\mathbf{z}_i$ ； $h_1(\cdot)$ 与 $h_0(\cdot)$ 分别表示干预组与对照组的独立预测网络。为了区分不同群体的样本，定义 $\mathcal{I}_t$ 与 $\mathcal{I}_c$ 分别为干预组与对照组的样本索引集合。

在优化算法方面，定义 $W_1(\cdot, \cdot)$ 为 Wasserstein 距离，用于度量两组样本分布的差异， π 表示最优传输方案， ϵ 与 L 分别代表 Sinkhorn 算法中的熵正则化系数与迭代次数。此外，为了处理长尾分布，定义 $\hat{p}(\mathbf{z})$ 为样本的核密度估计值， σ 为高斯核带宽参数。最后，定义 $\mathcal{L}_{fit}$ 、 $\mathcal{L}_{align}$ 与 $\mathcal{L}_{rank}$ 分别对应反事实预测损失、分布对齐损失与密度加权排序损失。在多目标损失函数中，定义 λ 为控制分布对齐损失 $\mathcal{L}_{align}$ 权重的超参数，定义 μ 为控制密度加权排序损失 $\mathcal{L}_{rank}$ 权重的超参数。表 3.1 汇总了上述主要符号及其说明。

表 3.1 第三章符号说明

符号	描述
$\mathcal{U}, N$	用户集合，样本总数
$\mathbf{x}_i, t_i, y_i^{obs}$	用户 i 的特征向量，干预指示变量，观测结果
$y_i(1), y_i(0)$	用户 i 在干预和对照条件下的潜在结果
$\tau(\mathbf{x})$	条件平均处理效应 CATE，即增益分数
$\Phi(\cdot), \mathbf{z}_i$	特征提取器（即编码器），用户 i 的隐特征表示
$h_1(\cdot), h_0(\cdot)$	干预组预测头，对照组预测头
$\mathcal{I}_t, \mathcal{I}_c$	干预组样本索引集合，对照组样本索引集合
$W_1(\cdot, \cdot), \pi$	Wasserstein 距离，最优传输方案
ϵ, L	Sinkhorn 算法中的熵正则化系数，迭代次数
$\hat{p}(\mathbf{z}), \sigma$	样本 $\mathbf{z}$ 的核密度估计值，高斯核带宽参数
$\mathcal{L}_{fit}, \mathcal{L}_{align}$	反事实预测损失，分布对齐损失
$\mathcal{L}_{rank}$	密度加权排序损失
λ	分布对齐损失权重系数
μ	密度加权排序损失权重系数




图 3.1 SDR 模型总体架构

3.3 基于 Sinkhorn 与样本密度排序的增益模型框架

SDR 模型的目标是协同优化选择偏差消除与增益排序能力，从而提供更精准的营销决策支持。如图 3.1 所示，SDR 模型主要由三个模块组成，即 (1) Y-Learner 增益预估基础网络、(2) 基于 Sinkhorn 算法的分布对齐模块和 (3) 基于样本密度加权的排序优化模块。

首先，为了灵活地拟合干预组和对照组可能存在的不同响应模式，设计了 **Y-Learner 增益预估基础网络**。该模块包括：(1) 共享特征提取器，用于从原始输入中提取高阶通用特征，并作为分布对齐的操作对象；(2) 独立预测头，分别构建干预组和对照组的专属分支网络，捕捉不同干预状态下的潜在结果分布。

其次，为了克服观测数据中普遍存在的选择偏差挑战，提出了 **基于 Sinkhorn 算法的分布对齐模块**。该模块包括：(1) Wasserstein 距离度量，利用其几何性质在高维空间中精确衡量干预组与对照组的特征分布差异；(2) Sinkhorn 算法求解，通过熵正则化的高效迭代算法，强制编码器学习到对干预分配不敏感的平衡表征，从而消除混淆变量的影响。

最后, 针对现有增益模型普遍侧重于因果效应值的精确拟合而忽视增益排序优化的问题, 提出了 **基于样本密度加权的排序优化模块**。该模块旨在直接优化因果效应的相对排序关系, 以满足精准营销中 Top-N 用户筛选的需求。同时, 为了克服长尾分布对排序学习的干扰, 该模块具体包括: (1) 基于高斯核的样本密度估计, 量化样本在特征空间中的稀疏程度; (2) 密度加权的成对排序损失, 通过基于样本密度的加权机制, 在显式优化排序目标的同时自适应地提升高密度主体样本的权重, 确保模型在长尾分布下仍能稳健学习到普遍的增益排序规律。

3.3.1 Y-Learner 增益预估基础网络

为了灵活地拟合干预组和对照组可能存在的不同响应模式, 我们摒弃了简单的将 t 作为特征的 S-Learner 架构, 转而采用多头网络架构, 本章称之为形似字母 Y 的 Y-Learner。该网络包含以下部分:

(1) **共享特征提取器 Shared Encoder Φ** : 输入原始特征 $\mathbf{x}$, 通过多层全连接网络 MLP 映射为隐特征 $\mathbf{z} = \Phi(\mathbf{x}; \theta_\phi)$ 。

$$\mathbf{z} = \sigma(W_l \dots \sigma(W_1 \mathbf{x} + b_1) \dots + b_l), \quad (3.6)$$

其中 σ 为非线性激活函数如 ReLU。该层负责提取高阶通用特征, 并作为分布对齐的操作对象。共享参数有助于在样本不足时利用两组数据的共性信息。

(2) **独立预测头 Prediction Heads h_1, h_0** : 在共享表征 $\mathbf{z}$ 之上, 分别构建两个独立的分支网络:

$$\hat{y}(1) = h_1(\mathbf{z}; \theta_1), \quad \hat{y}(0) = h_0(\mathbf{z}; \theta_0). \quad (3.7)$$

其中 h_1 仅利用干预组数据 ($t_i = 1$) 进行训练, h_0 仅利用对照组数据 ($t_i = 0$) 进行训练。这种解耦设计允许模型捕捉干预组和对照组截然不同的结果分布, 避免了 S-Learner 中干预变量 t 易被高维特征淹没的问题。

基础的反事实预测损失定义为观测数据上的均方误差:

$$\mathcal{L}_{fit} = \frac{1}{N} \sum_{i=1}^N [t_i \cdot (y_i^{obs} - \hat{y}_i(1))^2 + (1 - t_i) \cdot (y_i^{obs} - \hat{y}_i(0))^2] + \lambda \|\theta\|_2^2, \quad (3.8)$$

其中第二项为 L2 正则化项^[83,84], 防止过拟合。

3.3.2 基于 Sinkhorn 算法的分布对齐模块

为了消除选择偏差, 我们需要约束编码器 Φ , 使得 z 的分布在干预组和对照组之间“不可区分”。本章引入最优传输 (Optimal Transport) 理论^[15] 中的 Wasserstein 距离^[32] 作为差异度量, 并使用 Sinkhorn 算法^[85] 进行求解。

设干预组和对照组在隐空间中的经验分布分别为:

$$\mu = \sum_{i \in \mathcal{I}_t} \frac{1}{n_t} \delta_{z_i}, \quad \nu = \sum_{j \in \mathcal{I}_c} \frac{1}{n_c} \delta_{z_j}. \quad (3.9)$$

其中 $\mathcal{I}_t, \mathcal{I}_c$ 为样本索引集合, n_t, n_c 为样本量。两者的 Wasserstein 距离定义为 Kantorovich 问题的解:

$$W_1(\mu, \nu) = \min_{\pi \in \Pi(\mu, \nu)} \sum_{i=1}^{n_t} \sum_{j=1}^{n_c} \pi_{ij} C_{ij}, \quad (3.10)$$

其中:

- $C_{ij} = \|z_i - z_j\|_2$ 是成本矩阵, 表示从 z_i 移动到 z_j 的欧氏距离。
- $\Pi(\mu, \nu) = \{\pi \in \mathbb{R}_+^{n_t \times n_c} | \pi \mathbf{1} = \mu, \pi^T \mathbf{1} = \nu\}$ 是所有可能的联合传输方案集合, 满足边缘分布约束。

直接求解上述线性规划问题的复杂度为 $O(n^3 \log n)$, 这对于大规模深度学习训练是不可接受的。为了解决计算瓶颈并获得可微的损失函数, 我们采用熵正则化最优传输:

$$W_{1,\epsilon}(\mu, \nu) = \min_{\pi \in \Pi(\mu, \nu)} \sum_{i,j} \pi_{ij} C_{ij} - \epsilon H(\pi), \quad (3.11)$$

其中 $\epsilon > 0$ 为正则化系数, $H(\pi) = -\sum_{ij} \pi_{ij} \log \pi_{ij}$ 为香农熵。

引入熵正则项后, 原优化问题转化为一个严格凸问题, 其最优传输方案 π^* 具有特殊的几何结构, 即可以通过对吉布斯核矩阵 K 进行行、列缩放来获得。具体而言, Sinkhorn 算法利用交替投影的思想, 通过迭代更新两个缩放向量 $\mathbf{u}$ 和 $\mathbf{v}$, 使得传输矩阵 $P = \text{diag}(\mathbf{u})K\text{diag}(\mathbf{v})$ 逐步逼近并满足边缘分布约束 μ 和 ν 。这种基于矩阵运算的迭代求解方式不仅数值稳定性高, 且能够充分利用 GPU 的并行计算能力, 极大地提升了最优传输距离的计算效率, 使其适用于大规模深度学习任务。具体计算流程如下算法 3.3.1 所示:

算法 3.3.1: Sinkhorn 距离计算算法

Input: 特征矩阵 $Z_t \in \mathbb{R}^{n_t \times d}$, $Z_c \in \mathbb{R}^{n_c \times d}$, 正则化系数 ϵ , 最大迭代次数

L

Output: Sinkhorn 损失 $\mathcal{L}_{align}$, 最优传输方案 π^*

01: **步骤 1: 计算成本矩阵与吉布斯核**

02: $C_{ij} = \|Z_{t,i} - Z_{c,j}\|_2, \quad \forall i \in \{1 \dots n_t\}, j \in \{1 \dots n_c\}$

03: $K = \exp(-C/\epsilon)$

04: **步骤 2: Sinkhorn 迭代求解对偶变量**

05: 初始化 $\mathbf{v}^{(0)} = \mathbf{1}_{n_c}$

06: **for** $l = 1$ to L **do**

07: $\mathbf{u}^{(l)} = \mathbf{1}_{n_t} \oslash (K\mathbf{v}^{(l-1)})$

08: $\mathbf{v}^{(l)} = \mathbf{1}_{n_c} \oslash (K^T\mathbf{u}^{(l)})$

09: **end for**

10: **步骤 3: 计算最优传输方案与损失**

11: $\pi^* = \text{diag}(\mathbf{u}^{(L)})K\text{diag}(\mathbf{v}^{(L)})$

12: $\mathcal{L}_{align} = \sum_{i,j} \pi_{ij}^* C_{ij}$

13: **return** $\mathcal{L}_{align}, \pi^*$

Sinkhorn 算法仅涉及矩阵乘法和逐元素除法, 非常适合在 GPU 上并行化。通常只需 10-20 次迭代即可收敛。通过最小化 $\mathcal{L}_{align}$, 我们强制编码器 Φ 学习到对干预分配不敏感的平衡表征。

3.3.3 基于样本密度加权的排序优化模块

现有的增益模型主要优化 MSE^[5], 但 MSE 对排序不敏感^[12]。因此引入排序损失模块, 并针对长尾分布问题设计了样本密度加权机制。

为了直接优化增益排序目标, 我们采用组内成对排序 Intra-group Pairwise Ranking 的方法。对于干预组内的两个样本 $i, j \in \mathcal{I}_t$, 如果 $y_i^{obs} > y_j^{obs}$, 则说明在接受干预的情况下, 用户 i 的表现优于用户 j 。我们期望模型预测的干预组潜在结果也满足 $\hat{y}_i(1) > \hat{y}_j(1)$ 。同理适用于对照组。

我们采用一种基于回归差异的截断式平方损失函数。该损失函数仅对预测顺序与真实顺序不一致的样本对进行惩罚, 且惩罚力度取决于预测差值与真实差值的偏离程度。对于组内的一对样本 (i, j) , 其基础排序损失定义为:

$$\mathcal{L}_{rank}(i, j) = \begin{cases} 0, & (\hat{y}_i(t) - \hat{y}_j(t)) \cdot (y_i^{obs} - y_j^{obs}) \geq 0 \\ ((\hat{y}_i(t) - \hat{y}_j(t)) - (y_i^{obs} - y_j^{obs}))^2, & \text{otherwise} \end{cases} \quad (3.12)$$

这意味着, 如果模型预测的相对顺序(差值符号)与真实相对顺序一致, 则该样本对的损失为 0, 即模型认为该对样本已经“排对了”。仅当预测顺序相反时, 才计算损失。

关于密度加权机制设计的一个核心疑问在于: **“降低稀疏高价值样本的权重是否会导致模型忽略这些关键用户?”** 我们认为, 这种设计在增益模型框架下是合理且必要的, 原因在于 $\mathcal{L}_{fit}$ 与 $\mathcal{L}_{rank}$ 在优化目标上存在的分工互补: 稀疏的高价值用户(如高消费 VIP)通常具有显著且独特的特征模式。深度神经网络(Y-Learner)的特征提取器在最小化预测误差 $\mathcal{L}_{fit}$ 的过程中, 能够很容易地捕捉到这些强特征信号并给予准确的增益预估。换言之, 对于特征鲜明的极值样本, 基础回归损失已经足以保证其被模型正确识别, 无需在排序损失中通过高权重进行额外强调; 引入排序损失 $\mathcal{L}_{rank}$ 的核心目的, 并非是为了区分“极好”与“极差”的样本(这在特征层面通常是显而易见的), 而是为了在特征相似、区分度不高的主体人群(Body)中, 挖掘出细微的增益差异。主体区域样本密度大、噪声干扰多, 是排序学习的难点所在。

通过密度加权机制，我们实际上构建了一种“分层优化”策略：让 $\mathcal{L}_{fit}$ 负责全局数值的准确拟合（确保高价值用户不掉队），而引导 $\mathcal{L}_{rank}$ 聚焦于高密度的模糊区域（提升主体用户的排序分辨率）。这种策略既避免了稀疏离群点产生的梯度爆炸破坏隐空间结构，又显著提升了模型在全域范围内的细粒度排序能力，从而在 AUUC 指标上取得更优表现。

为了解决长尾分布带来的样本不平衡问题，并抑制异常值对模型的干扰，我们设计了**基于样本密度的加权机制**。我们希望调低 y 值过高的稀疏样本的权重，同时提高处于高密度区域的主体样本的权重。这有助于模型优先学习普遍的排序规律，避免被噪声主导。

首先，为了识别长尾分布中的极端值，我们需要量化每个样本在特征空间中的稀疏程度。采用高斯核密度估计 Gaussian KDE：假设在一个 Batch 中包含 B 个样本，对于样本 $\mathbf{z}_i$ ，其概率密度估计值 $\hat{p}_i$ 为：

$$\hat{p}(\mathbf{z}_i) = \frac{1}{B(2\pi\sigma^2)^{d/2}} \sum_{j=1}^B \exp\left(-\frac{\|\mathbf{z}_i - \mathbf{z}_j\|^2}{2\sigma^2}\right), \quad (3.13)$$

其中 σ 为带宽参数 Bandwidth。我们采用自适应带宽策略，设 σ 为当前 Batch 内所有样本对平均距离的 50%。

- **高密度区域**： $\hat{p}_i$ 较大，代表大多数普通用户，这是模型应该重点学习的主体。
- **低密度区域**： $\hat{p}_i$ 较小，代表稀疏的极端值 Outliers 或噪声，应降低其对模型的影响。

进而，定义样本对 (i, j) 的组合权重 w_{ij} 为两者概率密度的乘积：

$$w_{ij} = \hat{p}(\mathbf{z}_i) \cdot \hat{p}(\mathbf{z}_j), \quad (3.14)$$

- 当样本对处于高密度区域时， $\hat{p}(\mathbf{z}_i), \hat{p}(\mathbf{z}_j)$ 较大，权重 w_{ij} 较大，模型重点优化这些样本的排序关系。
- 当样本对包含低密度区域的稀疏样本时，权重 w_{ij} 较小，从而降低该样本

对产生的梯度。这相当于一种软性的去噪机制。

结合上述两部分，最终的密度加权排序损失定义为处理组 $\mathcal{T}$ 和对照组 $\mathcal{C}$ 内所有样本对的加权平均损失之和：

$$\mathcal{L}_{rank} = \frac{\sum_{i,j \in \mathcal{T}} w_{ij} \mathcal{L}_{rank}^{trt}(i, j)}{\sum_{i,j \in \mathcal{T}} w_{ij}} + \frac{\sum_{i,j \in \mathcal{C}} w_{ij} \mathcal{L}_{rank}^{cnt}(i, j)}{\sum_{i,j \in \mathcal{C}} w_{ij}}, \quad (3.15)$$

其中 $\mathcal{T}$ 和 $\mathcal{C}$ 分别表示处理组和对照组的样本集合。通过这种方式，我们在两个群体中分别优化排序能力，并利用密度加权机制增强了模型在长尾分布下的鲁棒性。

3.3.4 损失函数与训练算法

SDR 的总损失函数由预测损失、对齐损失和排序损失加权求和得到：

$$\mathcal{L}_{total} = \mathcal{L}_{fit} + \lambda \mathcal{L}_{align} + \mu \mathcal{L}_{rank}. \quad (3.16)$$

其中 λ_1 控制去偏的强度， λ_2 控制排序优化的强度。模型通过随机梯度下降 SGD 或 Adam 优化器进行端到端的联合训练。

3.4 实验与分析

为了全面且深入地评估所提出的 SDR 框架在处理选择偏差及优化增益排序方面的有效性，本节在包含真实业务场景与半合成反事实场景的多个基准数据集上开展了广泛的实证研究。具体的实验设计旨在回答以下四个核心研究问题

- **研究问题一：**与最先进的（SOTA）CATE 估计器相比，SDR 在估计准确性（如 PEHE, ATE 指标）方面的表现如何？
- **研究问题二：**SDR 在识别高价值增益用户方面的能力如何，研究提出的样本密度排序损失模块是否提升了模型的排序能力
- **研究问题三：**SDR 中的各个组件（Sinkhorn 分布对齐、密度加权排序）是否都对提升模型的整体性能做出了贡献？

- **研究问题四：** 关键超参数如何影响 SDR 的性能？

3.4.1 实验设置

(1) 数据集设置。 为了评估 SDR 的性能，本章在三个数据集上进行了广泛实验：两个真实基准数据集 **Hillstrom-Man** 和 **Hillstrom-Woman**^[12,86]，以及一个半合成数据集 **MovieLens-100K**^[87]。其中，MovieLens-100K 被专门构建用于评估反事实估计的准确性（研究问题一）。

Hillstrom 数据集： 该数据集源自真实的电子邮件营销场景，记录了 64,000 名消费者在收到电子邮件营销活动后的两周内的行为数据，包括访问（visit）、转化（conversion）和花费（spend）。原始数据集包含三种数据类型：*mens_email*、*womens_email* 和 *no_email*。我们将来自 *mens_email* 和 *womens_email* 的数据分配干预变量 $T = 1$ ，表示分配了激励；而来自 *no_email* 的数据分配 $T = 0$ ，表示未分配激励。我们将 *mens_email* 干预组与 *no_email* 对照组合并，形成 **Hillstrom-Man** 数据集；同理，将 *womens_email* 干预组与 *no_email* 对照组合并，构成 **Hillstrom-Woman** 数据集。我们选择用户的“花费金额（Spend）”作为核心转化指标 Y 。

MovieLens-100K 数据集： MovieLens-100K 主要记录了电影推荐系统中用户对电影的五星评分。然而，它不包含激励分配信息或相应的事实和反事实结果。因此，我们基于 MovieLens-100K 中的观测评分合成了一个新数据集，以验证反事实估计的准确性。具体而言，我们首先选择交互最多的前 100 名用户和前 100 个物品，形成 10,000 个用户-物品对。接下来，我们将具有观测评分的用户-物品对归类为干预组，将没有观测评分的归类为对照组。选择前 100 名用户和物品的原因是为了确保干预组中的用户-物品对数量不会显著低于对照组。然后，我们使用预训练的神经协同过滤（NCF）模型^[88]来预测并填充对照组中缺失的评分。最后，我们按如下方式生成事实和反事实结果：

- 对于评分 ≤ 3 的用户-物品对，我们假设无论是否分配激励，用户都不会购买该物品，即 $Y(1) = Y(0) = 0$ 。
- 对于评分 ≥ 3 的前 50% 用户-物品对，我们假设无论是否分配激励，用户都会购买该物品，即 $Y(1) = Y(0) = 1$ 。

- 对于评分 ≥ 3 的后 50% 用户-物品对，我们认为它们对激励敏感：如果分配激励，用户将购买该物品，否则不购买，即 $Y(1) = 1$ 和 $Y(0) = 0$ 。

数据集的详细统计数据如表 3.2 所示。

表 3.2 数据集统计信息

数据集	总样本数	干预组样本数	对照组样本数	转化指标
Hillstrom-Man	42,613	21,306	21,307	Spend
Hillstrom-Woman	42,693	21,306	21,387	Spend
MovieLens-100K	10,000	5,821	4,179	Rating

(2) **基线模型**。为了全面评估模型性能，我们选取了涵盖统计估计算法、匹配估计算法和表征学习算法的广泛基线方法进行对比：

• **统计估计算法 (Statistical Estimators)**

- **OLS (Ordinary Least Squares)**: 普通最小二乘回归。作为最基础的统计学方法，OLS 假设协变量、干预变量与结果变量之间存在线性关系。它将干预变量作为一个普通特征，通过最小化预测误差的平方和来估计处理效应。
- **R.Forest (Random Forest)**: 随机森林模型。这是一种基于决策树的集成学习方法，它通过大量决策树的投票或平均来预测潜在结果。相比于线性模型，它具有较强的非线性拟合能力，能更好地处理高维特征。
- **S-Learner^[11]**: 单模型学习器。S-Learner 将干预变量 T 与协变量 X 拼接作为输入，训练一个统一的神经网络模型来预测结果 Y 。CATE 的估计通过计算 $\hat{Y}(X, T=1) - \hat{Y}(X, T=0)$ 获得。这种方法简单易行，但在干预效应较弱时，模型可能会倾向于忽略干预变量，导致估计偏差 (Regularization Bias)。
- **T-Learner^[11]**: 双模型学习器。T-Learner 分别为干预组和对照组训练两个独立的回归模型 $\mu_1(X)$ 和 $\mu_0(X)$ 。CATE 估计值为两个模型预测值的差。这种方法避免了干预变量被忽略的问题，但由于两个模型独立训练，可能会导致两个模型的误差累积，且在样本量较小的一组上

容易过拟合。

- **TarNet**^[5]: TarNet 是一种经典的深度学习 CATE 估计器。它首先通过共享的神经网络层学习输入特征的平衡潜在表征 $\Phi(X)$ ，然后将其分别输入到两个独立的分支网络（干预头和对照头）中预测结果，是许多后续表征学习方法的骨干网络。

- **匹配估计算法 (Matching Estimators)**

- **C.Forest (Causal Forest)**^[24]: 因果森林。这是随机森林在因果推断领域的扩展。与传统随机森林不同，因果森林的分裂准则旨在最大化处理效应的异质性，而非仅仅最小化预测误差，通过将样本分为两部分分别用于树的结构生长和叶节点效应估计，从而提供渐近无偏的 CATE 估计。
- **O.Forest (Orthogonal Forest)**^[24]: 正交森林。正交森林结合了正交化（Orthogonalization）技术和因果森林。通过两步过程消除干扰参数带来的偏差，从而在存在混杂因素的情况下提供更稳健的 CATE 估计。

- **表征学习估计算法 (Representation-Based Estimators)**

- **CFR-MMD**^[5]: 基于 MMD 的反事实回归。CFR-MMD 在 TarNet 的基础上引入了分布平衡正则化项。它使用最大均值差异（Maximum Mean Discrepancy, MMD）来度量干预组和对照组在潜在表征空间中的分布差异，并通过最小化该差异来减少选择偏差（Selection Bias），使得模型在推断反事实结果时更加准确。
- **CFR-WASS**^[5]: 基于 Wasserstein 距离的反事实回归。与 CFR-MMD 类似，但它采用 Wasserstein 距离作为分布差异的度量。
- **ESCFR**^[54]: 熵正则化最优传输反事实回归。ESCFR 引入了熵正则化的最优传输来计算分布距离，进一步提升了模型在处理大规模高维数据时的稳定性和泛化能力。

(3) 评估指标。为了全方位验证模型表现，我们采用了兼顾增益效应估计准确性与群体营销投放排序能力的综合评价指标：

- **估计准确性指标**: 由于真实反事实结果通常不可得，我们使用半合成数据

集 MovieLens-100K，并采用以下指标评估 CATE 估计的准确性 [5,89,90]：

- ϵ_{PEHE} (Precision in Estimation of Heterogeneous Effect): 衡量个体级 CATE 估计的均方根误差，该值越小，说明估计越准确。

$$\epsilon_{PEHE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (\hat{\tau}(\mathbf{x}_i) - \tau(\mathbf{x}_i))^2}. \quad (3.17)$$

- ϵ_{ATE} (Average Treatment Effect Error): 衡量平均处理效应 (ATE) 的估计误差。

$$\epsilon_{ATE} = \left| \frac{1}{N} \sum_{i=1}^N \hat{\tau}(\mathbf{x}_i) - \frac{1}{N} \sum_{i=1}^N \tau(\mathbf{x}_i) \right|. \quad (3.18)$$

- ϵ_{ATT} (Average Treatment Effect on the Treated Error): 衡量干预组平均处理效应 (ATT) 的估计误差。由于在观测数据中选择偏差的存在，干预组的分布往往与总体分布不同，该指标专门评估模型在实际接受干预群体上的推断准确性。

$$\epsilon_{ATT} = \left| \frac{1}{|\mathcal{T}|} \sum_{i \in \mathcal{T}} \hat{\tau}(\mathbf{x}_i) - \frac{1}{|\mathcal{T}|} \sum_{i \in \mathcal{T}} \tau(\mathbf{x}_i) \right|. \quad (3.19)$$

其中 $\mathcal{T}$ 表示干预组样本集合。

- **排序能力指标**: 针对真实数据集 Hillstrom-Man 和 Hillstrom-Woman，由于缺乏个体级的反事实真值，我们无法直接计算 PEHE。因此，我们采用业界通用的基于排序的评估指标。这些指标的核心思想是：如果模型能够准确预测增益效应，那么根据预测值降序排列后，排在前面的用户应该具有更高的真实增益。

- **AUUC (Area Under the Uplift Curve)**: 衡量累积增益曲线 (Uplift Curve) 下的面积。Uplift 曲线反映了在针对前 ρ 比例的用户进行干预时所获得的累积净增益。

$$f_{Uplift}(\rho) = \left(\frac{Y_t(\rho)}{N_t(\rho)} - \frac{Y_c(\rho)}{N_c(\rho)} \right) (N_t(\rho) + N_c(\rho)). \quad (3.20)$$

其中, $N_t(\rho)$ 和 $N_c(\rho)$ 分别表示在前 ρ 比例用户中干预组和对照组的样本数量, $Y_t(\rho)$ 和 $Y_c(\rho)$ 分别表示相应的转化结果总和 (如总消费金额)。AUUC 即为该曲线下的面积:

$$AUUC = \int_0^1 f_{Uplift}(\rho) d\rho. \quad (3.21)$$

AUUC 越大, 说明模型将高增益用户排在前面的能力越强。

- **AUQC (Area Under the Qini Curve):** 衡量 Qini 曲线下的面积。Qini 曲线是 Uplift 曲线的变体, 对干预组和对照组样本比例不平衡的情况更加鲁棒。其定义如下:

$$f_{Qini}(\rho) = Y_t(\rho) - \frac{N_t}{N_c} Y_c(\rho). \quad (3.22)$$

其中 N_t 和 N_c 是整个数据集的干预组和对照组总样本数。同样, AUQC 为该曲线下的面积:

$$AUQC = \int_0^1 f_{Qini}(\rho) d\rho. \quad (3.23)$$

- **LIFT@K:** 衡量模型预测增益排名前 K (如前 10%, 30%) 的用户群体的平均干预效应 (Average Treatment Effect on the Treated Group)。

$$LIFT@K = \frac{Y_t(K)}{N_t(K)} - \frac{Y_c(K)}{N_c(K)}. \quad (3.24)$$

该指标直观地反映了如果仅对模型推荐的前 K 比例用户进行营销, 相比于对照组能够带来的平均提升幅度。

3.4.2 结果与分析

我们系统性地评估了 SDR 与各基线模型在 MovieLens-100K 半合成数据集上的反事实估计准确性, 并在真实的 Hillstrom 数据集上验证了模型的业务排序

能力。

(1) CATE 估计准确性分析 (研究问题一)。表 3.3 详细列出了各模型在训练集 (In-Sample) 和测试集 (Out-of-Sample) 上的 ϵ_{PEHE} 、 ϵ_{ATE} 以及 ϵ_{ATT} 表现。数据表明, SDR 在所有准确性指标上均显著优于对比基线。在 Out-of-Sample 测试中, SDR 的个体级因果效应误差 ϵ_{PEHE} 降至 0.4935, 相较于次优的 ESCFR (0.5202) 降低了约 **5.1%**。在衡量全局平均效应的 ϵ_{ATE} 指标上, SDR 仅为 0.1544, 相比 ESCFR (0.2037) 实现了 **24.2%** 的误差缩减。此外, SDR 在干预组平均效应 ϵ_{ATT} 上也达到了 0.0291 的极高精度, 显著优于 CFR-WASS (0.0499)。这有力地证明了引入 Sinkhorn 最优传输算法能更精细地对齐干预组与对照组的高维特征分布, 从而有效克服选择偏差, 精准还原潜在的因果效应。纵向对比来看, 显式引入分布平衡正则项的方法 (SDR, ESCFR, CFR-WASS, CFR-MMD) 在各项指标上普遍优于传统的统计模型 (OLS, S-Learner) 和树模型 (R.Forest, C.Forest)。例如, CFR-MMD 的 ϵ_{ATE} (0.2081) 显著低于 TarNet (0.2759), 验证了在观测数据下消除协变量分布差异对于无偏估计的必要性。而在分布对齐方法内部, 基于 Wasserstein 距离的方法 (SDR, ESCFR, CFR-WASS) 又优于基于 MMD 的方法, 表明 Wasserstein 距离在处理互不重叠支撑集 (Disjoint Support) 问题上具有更好的几何特性和梯度指引能力。

(2) 模型排序能力分析 (研究问题二)。为了验证模型在实际业务中的决策价值, 我们在 Hillstrom-Man、Hillstrom-Woman 及 MovieLens-100K 数据集上评估了增益模型排序性能。表 4.3 展示了各模型在 AUUC、AUQC 和 LIFT@100 指标上的表现。实验结果表明, SDR 在三个数据集上均取得了最优的排序效果。以 Hillstrom-Man 数据集为例, SDR 的 AUUC 达到 0.5863, 相比于次优模型 ESCFR (0.4631) 提升了约 **26.6%**; 在衡量头部用户转化的 LIFT@100 指标上, SDR 更是达到了 1.1742, 远超其他基线。这一优势在 Hillstrom-Woman 数据集上同样显著, AUUC 提升至 0.7121, LIFT@100 达到 3.1399, 充分说明 SDR 能够稳健地识别出对干预最敏感的高价值用户群体。值得注意的是, 虽然部分基线模型 (如 CFR-WASS) 在 CATE 估计误差上表现尚可, 但在排序指标 AUUC 上却不如人意。这揭示了传统的 MSE 损失函数与业务排序目标之间的不一致性。SDR 通过

表 3.3 SDR 模型与基线模型的 CATE 估计准确性指标对比

Mode	In-Sample			Out-of-Sample		
	$\epsilon_{\text{PEHE}} \downarrow$	$\epsilon_{\text{ATE}} \downarrow$	$\epsilon_{\text{ATT}} \downarrow$	$\epsilon_{\text{PEHE}} \downarrow$	$\epsilon_{\text{ATE}} \downarrow$	$\epsilon_{\text{ATT}} \downarrow$
OLS	0.6275	0.4151	0.2883	0.6350	0.4216	0.2923
R.Forst	0.5331	0.2505	0.3772	0.5339	0.244	0.3733
S.Learner	0.5225	0.2125	0.0854	0.5297	0.2199	0.0893
T.Learner	0.6063	0.2194	0.1055	0.6691	0.2519	0.1281
TarNet	0.5422	0.2694	0.1427	0.5492	0.2759	0.1466
C.Forest	0.5143	0.1862	0.3164	0.5166	0.1780	0.3099
O.Forest	0.5357	0.1969	0.0734	0.5440	0.1960	0.0730
CFR - MMD	0.5411	0.1957	0.0712	0.5539	0.2081	0.0800
CFR - WASS	0.5328	0.1598	0.0438	0.5469	0.1662	0.0499
ESCFR	0.5094	0.2003	0.0772	0.5202	0.2037	0.0776
SDR	0.4832	0.1496	0.0282	0.4935	0.1544	0.0291

引入密度加权的 RankLoss，直接优化预测值的相对序关系，并利用密度权重抑制了长尾样本的噪声干扰。从结果看，即使是在 CATE 估计上表现一般的模型，若能结合排序优化，往往也能在 AUUC 上获得提升，而 SDR 结合了精准的因果推断（Sinkhorn）和直接的排序优化（RankLoss），因此实现了最佳的综合性能。

表 3.4 SDR 模型与基线模型的增益排序指标对比

Dataset	Hillstrom-Man			Hillstrom-Woman			MovieLens-100K		
	AUUC $\uparrow$	AUQC $\uparrow$	LIFT@100 $\uparrow$	AUUC $\uparrow$	AUQC $\uparrow$	LIFT@100 $\uparrow$	AUUC $\uparrow$	AUQC $\uparrow$	LIFT@100 $\uparrow$
OLS	0.3665	0.2669	-2.8228	0.0863	0.2600	0.2240	0.5013	0.3304	0.2800
R.Forst	0.4148	0.2991	-0.9502	0.4272	0.2324	1.3317	0.4832	0.3238	0.2000
S.Learner	0.3550	0.2770	0.4496	0.2294	0.2314	-2.5451	0.5257	0.3507	0.2000
T.Learner	0.4210	0.3127	-3.9439	0.3342	0.1768	-2.9667	0.4989	0.3466	0.4000
TarNet	0.4543	0.3219	0.5823	0.2073	0.1648	1.2447	0.5048	0.3374	0.3200
C.Forest	0.3920	0.2691	0.7856	0.3652	0.2302	-0.5261	0.5305	0.3432	0.3000
O.Forest	0.4820	0.3125	0.7247	0.3904	0.2806	-0.6381	0.5309	0.3517	0.2300
CFR-MMD	0.4633	0.3147	-0.4554	0.2246	0.1571	1.2313	0.6069	0.3917	0.3600
CFR-WASS	0.4702	0.3184	0.6701	0.3545	0.2923	-0.7702	0.6187	0.3953	0.3800
ESCFR	0.4631	0.3326	0.7258	0.3575	0.2668	1.5103	0.6233	0.3985	0.4200
SDR	0.5863	0.3871	1.1742	0.7121	0.4406	3.1399	0.62962	0.39557	0.4700

3.4.3 消融实验

为了系统性地解构 SDR 框架中各个关键组件的贡献（研究问题三），我们在 Hillstrom-Man 数据集上开展了深入的消融研究。我们构建了四个具有不同配置的变体模型，逐步引入最优传输对齐（Sinkhorn OT）和密度加权排序损失（RankLoss）模块，并对比它们在 In-Sample（训练集）与 Out-of-Sample（测试集）上的性能表现。具体实验结果汇总于表 4.4。基于实验数据，我们可以得出以下结论：

Sinkhorn 最优传输有力提升模型泛化能力。对比第一行（TarNet）与第三行（Only OT），引入 Sinkhorn 分布对齐后，模型在 Out-of-Sample 测试集上的性能实现了提升。AUUC 从 0.4543 提升至 0.5709，涨幅高达 **25.7%**；LIFT@100 从 0.5823 翻倍至 1.1721。这一结果强有力地证明，Sinkhorn 算法通过在高维特征空间中拉齐干预组与对照组的分布，有效消除了选择偏差，从而显著降低了反事实推断的泛化误差，使模型在未见数据上也能保持稳健的表现。

密度加权排序损失直接强化了业务目标优化。对比第一行（TarNet）与第二行（Only RankLoss），仅引入排序损失也能带来明显的性能增益。Out-of-Sample 的 AUUC 提升至 0.5230，LIFT@100 提升至 1.081。这表明，在传统的回归损失之外，显式地引入排序信号能够引导模型更关注样本间的相对优劣关系。特别是密度加权机制，通过降低长尾分布中稀疏噪声样本的权重，使模型聚焦于主体数据的排序规律学习，从而在不依赖分布对齐的情况下也能改善排序质量。

表中第四行（SDR）的结果显示，当同时集成 OT 对齐与 RankLoss 优化时，模型在所有指标上均达到了最优水平。Out-of-Sample 的 AUUC 攀升至 0.5807，LIFT@100 达到了 2.0146。值得注意的是，这一性能提升源于两个单模块效果的协同效应。Sinkhorn 对齐构建了无偏的特征空间，而密度加权排序损失则在此基础上精细化了梯度的方向，进一步挖掘了特征空间中的因果排序结构。

表 3.5 SDR 在 Hillstrom-Man 数据集上的消融实验结果

Components		In-Sample			Out-of-Sample		
OT	RankLoss	AUUC↑	AUQC↑	LIFT@100↑	AUUC↑	AUQC↑	LIFT@100↑
×	×	0.5351	0.3382	0.5998	0.4543	0.3219	0.5823
×	✓	0.5362	0.3473	0.6996	0.5230	0.3636	1.0811
✓	×	0.5927	0.3992	0.7584	0.5709	0.3801	1.1721
✓	✓	0.6697	0.4018	0.7889	0.5863	0.3871	1.1742

3.4.4 超参数敏感性分析

为了评估 SDR 模型对关键超参数的鲁棒性并确定最佳参数配置（研究问题四），我们在 Hillstrom-Man 数据集上进行了超参数敏感性分析。本节重点考察三个核心超参数：Sinkhorn 熵正则化系数 ϵ 、分布对齐损失权重 λ 以及密度加权排序损失权重 μ 。图 4.3 展示了不同参数取值下模型在 AUUC、AUQC 和 LIFT@100 三个指标上的性能变化趋势。

(1) 正则化系数 ϵ 控制着最优传输方案的熵约束强度，直接影响分布对齐的平滑度与计算稳定性。如图 4.3 (a, d, g) 所示，随着 ϵ 的增加，各项性能指标呈现先升后降的倒 U 型趋势：当 ϵ 过小（如 $< 10^{-2}$ ）时，Sinkhorn 算法趋近于原始的 Wasserstein 距离计算，此时传输方案变得稀疏，数值计算稳定性下降，且容易导致模型对训练数据的噪声过拟合，从而降低了模型的泛化性能；当 ϵ 过大（如 $> 10^{-1}$ ）时，熵正则项主导了优化目标，导致传输方案趋于均匀分布。这削弱了最优传输对特征分布差异的度量能力，使得干预组和对照组的特征分布未能得到充分对齐，残留的选择偏差影响了增益效应的估计准确性。实验结果表明，当 ϵ 取值在 10^{-1} 附近时，模型在 AUUC、AUQC 和 LIFT@100 指标上均达到峰值。这表明适度的熵正则化能够在保证对齐精度的同时提升计算稳定性与泛化能力。因此，我们在后续实验中固定 $\epsilon = 0.1$ 。

权重 λ 调节了模型在“反事实拟合”与“分布对齐”两个目标之间的权衡。如图 4.3 (b, e, h) 所示：当 λ 较小（如 $< 10^{-1}$ ）时，模型主要关注观测数据的拟合误差，对分布差异的惩罚不足，导致未能有效消除选择偏差，限制了模型性能的提升；随着 λ 增加至 10^0 附近，各项指标显著提升并达到最优。这说明引入足够强度的分布对齐约束能够帮助模型学习到更加平衡的特征表示，从而提升




图 3.2 SDR 模型性能指标随超参数变化的趋势分析

因果推断的准确性；然而，当 λ 过大（如 $> 10^1$ ）时，模型过度关注分布对齐而牺牲了对结果变量的拟合能力，导致特征表示丢失了部分预测所需的语义信息，反而引起性能下降。因此，我们选择 $\lambda = 1.0$ 作为默认设置。

权重 μ 控制了密度加权排序损失对模型优化的贡献程度。如图 4.3 (c, f, i) 所示：当 μ 较小（如 $< 10^{-2}$ ）时，模型主要依赖回归损失进行优化，对样本间的相对排序关系关注不足，导致排序指标（AUUC, LIFT@100）表现一般；随着 μ 增加至 10^{-2} 左右，模型性能达到峰值。这表明适度引入排序信号能够引导模型更关注高价值用户的识别，有效提升了增益排序能力；当 μ 进一步增大（如 $> 10^{-1}$ ）时，排序损失可能与回归损失产生梯度冲突，导致模型难以收敛到最优解，性能出现明显下滑。因此，我们将 μ 设定为 0.01 以平衡拟合与排序目标。

3.5 本章小结

本章提出了基于 Sinkhorn 与样本密度排序的增益模型 (SDR)。针对增益模型中面临的高维选择偏差以及排序学习缺失与长尾分布干扰这两大核心挑战, 我们构建了一套协同优化的解决方案。在理论层面, 利用 Sinkhorn 算法的高效性与 Wasserstein 距离的几何特性, 实现了高维特征空间的深度对齐, 有效消除了选择偏差; 同时, 通过引入密度加权排序机制, 在直接优化排序目标的同时抑制了长尾噪声的影响, 填补了传统增益模型在排序学习上的空白。在实验层面, Hillstrom-woman、Hillstrom-man 与 MovieLens-100K 数据集上的广泛测试表明, SDR 在 PEHE、ATE、AUUC 等关键指标上均显著优于现有的模型。深入的消融实验进一步证实了分布对齐与排序优化模块的有效性与互补性。本章工作不仅验证了“分布对齐与排序学习”范式的优越性, 也为解决复杂分布下的精准营销决策问题提供了一种鲁棒、高效的新思路。

第4章 GradNorm 增强的结构化排序增益模型与评估办法

本章从“结构化分布对齐与多目标协同优化”的建模角度出发，在第三章的研究基础上，聚焦于增益模型在复杂场景下面临的两个深层挑战：一方面，基础的分布对齐方法仅关注特征边缘分布的一致性，忽略了特征空间内部固有的几何拓扑结构，导致去偏不彻底且易破坏数据的流形特征；另一方面，在引入强力的对齐约束后，多任务间的梯度竞争日益激烈，排序目标的梯度往往被对齐目标的梯度所抑制，导致排序学习在训练过程中失效。为解决以上问题，本章在 SDR 框架的基础上，提出了 GradNorm 增强的结构化排序增益模型 GSDR。该模型引入 Fused Gromov-Wasserstein (FGW) 距离以实现特征分布与几何结构的双重对齐，并利用 GradNorm 动态加权算法平衡多任务梯度流，确保排序目标在强对齐约束下仍能被有效优化，从而实现增益模型在结构化去偏与排序精度上的全面提升。

4.1 引言

在上一章中，我们提出了基于 Sinkhorn 算法与样本密度加权排序损失的 SDR 框架，利用最优传输理论有效地解决了特征空间中的全局分布对齐问题，显著降低了由选择偏差带来的因果效应估计误差并提升了模型的排序能力。然而，随着研究的深入和业务场景的日益复杂化，特别是在面对具有高度非线性和群体结构特征的数据时，我们发现基础框架在处理更加精细的因果推断任务时仍存在显著的局限性。这些局限性主要体现在以下两个进阶挑战中：

挑战一：特征对齐中的几何结构丢失：传统的 Wasserstein 距离本质上是一种“点对点”（Point-wise）的传输成本度量，其核心目标是最小化将干预组样本移动到对照组样本的总位移成本。这种对齐方式虽然在宏观上拉齐了两个边缘分布，但往往忽视了数据内部的拓扑结构。在真实的用户增长与营销场景中，用户特征并不是独立均匀分布的，而是呈现出明显的流形结构或聚类特征。例如，

对价格敏感的用户可能聚集成一个簇，而对品牌忠诚的用户聚集成另一个簇。如果模型在消除选择偏差时，仅仅强行将干预组的分布“压”到对照组的分布上，而不考虑这些内在的簇结构，很可能会破坏用户之间的相似性关系，使得原本相似的用户在隐空间中变得不再相似，从而严重损害增益预测准确性。

挑战二：强对齐约束下的排序学习失效：SDR 虽然设计了专门的排序损失函数，但在引入复杂的结构化对齐后，排序精度的提升面临新的困境。SDR 本质上是一个典型的多任务学习（Multi-Task Learning），涉及三个相互竞争的子目标：准确估计反事实结果（拟合目标）、消除分布差异（对齐目标）以及识别高价值用户（排序目标）。在训练初期，强力的对齐损失通常产生主导性的梯度，导致模型将大部分优化资源集中在“拉齐分布”上。相比之下，排序任务的梯度信号往往较为微弱且不稳定，容易在强力的对齐约束下被抑制。这种任务间的不平衡导致模型虽然实现了很好的去偏效果，但最终的排序性能（AUUC）却提升有限。这意味着，仅仅设计好的排序损失函数是不够的，我们还需要一种机制来确保排序目标在整个训练过程中都能被有效地优化。

为了突破上述局限，本章在基础框架的基础上，进一步提出了一个 **Grad-Norm 增强的结构化排序增益模型**，简称 **GSDR**。该框架旨在从“几何结构保留”和“排序鲁棒性”两个维度对第三章提出的 SDR 进行深层次的改进。具体而言，本章的主要创新点总结如下：

- **引入 Fused Gromov-Wasserstein (FGW) 距离^[91] 实现结构化去偏。**我们将最优传输的度量标准从单纯的 Wasserstein 距离^[32] 升级为 FGW 距离。FGW 距离是一个具有开创性的度量工具，它不仅考虑了样本特征在嵌入空间中的绝对距离（Feature Distance），还引入了 Gromov-Wasserstein 项^[92] 来度量样本对（Pairwise）之间关系结构的差异（Structure Distance）。这使得 GSDR 在对齐干预组和对照组分布的同时，能够最大程度地保留各自数据内部的拓扑结构和流形特征，实现了真正的“结构感知”深度去偏。
- **引入 GradNorm 动态优化算法保障排序精度。**针对排序目标容易被其他任务主导的问题，我们引入了基于梯度的自适应优化算法（GradNorm）。该算法通过实时监控各个任务的梯度模长，动态调整拟合、对齐和排序三个

任务的损失权重。它能够自动“放大”被抑制的排序任务的梯度信号，防止其在训练过程中掉队，从而确保模型能够持续、稳定地学习增益排序规律，最终实现排序精度的最大化。

- **在复杂景下的全面评估。**为了验证进阶框架处理复杂结构数据的能力，本章节使用 MovieLens-100K、Hillstrom-Man、Hillstrom-Woman 三项开源数据集，广泛的实验结果表明，GSDR 不仅在传统的 AUUC 指标上显著优于基础框架及其他 SOTA 方法，而且在特征结构保留度（LNC 指标）和训练稳定性上展现出了卓越的性能。

4.2 问题描述与定义

在本节中，我们将从几何拓扑的数学视角，对因果增益建模中面临的结构对齐问题与多任务冲突问题进行形式化刻画。

4.2.1 特征分布对齐的拓扑结构一致性问题

在消除选择偏差的过程中，传统的分布对齐方法（如基于 Wasserstein 距离的 Sinkhorn 算法）主要关注特征空间中边缘分布的匹配。设干预组与对照组的特征分布分别为 μ_t 和 μ_c ，特征映射函数为 Φ 。经典方法的优化目标为寻找最优传输方案 π^* 以最小化点对点传输成本：

$$\min_{\pi \in \Pi(\mu_t, \mu_c)} \sum_{i,j} d(\Phi(\mathbf{x}_i^t), \Phi(\mathbf{x}_j^c)) \pi_{ij}. \quad (4.1)$$

然而，这种仅约束边缘分布一致性（即 $P(\Phi(X)|T=1) \approx P(\Phi(X)|T=0)$ ）的方法忽略了数据流形的**拓扑几何结构**。在数学上，Wasserstein 距离对于保持样本间的相对距离（Isometry）不具备约束力。若映射 Φ 导致特征空间发生非线性扭曲，即干预组中相邻的样本在映射后对应的对照组样本不再相邻，则破坏了因果推断中的**局部平滑性假设**。

我们将这一问题形式化为**结构畸变（Structure Distortion）**最小化问题。定

义干预组内的距离矩阵为 $\mathbf{D}^t$ (其中 $D_{ik}^t = d(\mathbf{x}_i^t, \mathbf{x}_k^t)$)，对照组内的距离矩阵为 $\mathbf{D}^c$ 。理想的去偏映射应当近似满足**等距同构**性质，即最小化 Gromov-Wasserstein 差异：

$$\mathcal{L}_{GW}(\pi) = \sum_{i,j,k,l} |D_{ik}^t - D_{jl}^c|^2 \pi_{ij} \pi_{kl}. \quad (4.2)$$

引入 FGW (Fused Gromov-Wasserstein) 旨在联合优化特征匹配成本与结构畸变成本，解决 Sinkhorn 算法导致的几何结构丢失问题，确保在对齐分布的同时保留“相似用户具有相似增益”的流形特征。

4.2.2 多任务学习中的梯度冲突与帕累托稳定

增益模型本质上是一个多目标优化 (Multi-Objective Optimization, MOO) 问题，需同时最小化拟合损失 $\mathcal{L}_{fit}$ 、对齐损失 $\mathcal{L}_{align}$ 和排序损失 $\mathcal{L}_{rank}$ 。设参数向量为 θ ，损失向量为 $\mathcal{L}(\theta) = [\mathcal{L}_1, \dots, \mathcal{L}_m]^T$ 。传统的静态线性加权方法 $\min_{\theta} \sum_{k=1}^m w_k \mathcal{L}_k(\theta)$ 隐含地假设了各任务梯度的协同性。然而，在实际训练中，主要面临以下两类数学挑战：

- **梯度量级失衡 (Gradient Magnitude Disparity)**: 不同任务的梯度范数差异显著，即 $\exists i, j, \|\nabla_{\theta} \mathcal{L}_i\| \gg \|\nabla_{\theta} \mathcal{L}_j\|$ 。这导致优化轨迹被高梯度任务（通常为分布对齐项）主导，使得模型在其他关键任务（如增益排序）上收敛缓慢甚至停滞。
- **梯度方向冲突 (Gradient Direction Conflict)**: 任务间的梯度方向可能存在负相关，即 $\langle \nabla_{\theta} \mathcal{L}_i, \nabla_{\theta} \mathcal{L}_j \rangle < 0$ 。此时，沿某一任务的最优下降方向更新参数可能会导致另一任务的损失增加。

因此，我们的目标不再是寻找单一标量损失的极小值，而是寻找多目标优化的**帕累托平稳点 (Pareto Stationary Point)** θ^* 。在该点上，不存在任何可行下降方向 $\mathbf{d}$ 能够同时降低所有目标的损失，即满足：

$$\nexists \mathbf{d} \in \mathbb{R}^n, \text{ s.t. } \langle \nabla_{\theta} \mathcal{L}_k(\theta^*), \mathbf{d} \rangle < 0, \quad \forall k \in \{1, \dots, m\} \quad (4.3)$$

解决这一问题的关键在于引入基于梯度的动态加权机制，平衡梯度模长并修正更新方向，从而逼近帕累托前沿。

4.2.3 符号定义

为了清晰地描述本章提出的 GSDR 进阶模型，本节将对涉及的核心数学符号进行详细阐释。本章的符号体系主要涵盖 FGW 结构对齐与 GradNorm 动态优化两个模块。

在 FGW 结构对齐模块中，定义 C_{ij} 为特征成本矩阵（Feature Cost Matrix），用于度量源域样本 i 与目标域样本 j 在特征空间中的欧氏距离，反映了两者在数值属性上的差异； D_{ik}^s 与 D_{jl}^t 分别表示源域（Source Domain）与目标域（Target Domain）内部的结构成本矩阵（Structure Cost Matrix），它们刻画了样本对 (i, k) 与 (j, l) 在各自数据流形上的几何距离（如样本间的相对位置关系）。 $L(C_{ij}, D_{ik}^s, D_{jl}^t)$ 表示 FGW 的张量损失函数，它综合考量了特征匹配成本与结构一致性成本。 $\alpha \in [0, 1]$ 为平衡超参数，用于调节模型对特征对齐与结构保留的关注程度：当 α 增大时，模型更倾向于保持几何拓扑结构的一致性。 $\mathcal{L}_{FGW}$ 则表示最终计算得到的 Fused Gromov-Wasserstein 损失值。在 GradNorm 多目标优化模

表 4.1 第四章符号说明

符号	描述
C_{ij}	特征成本矩阵，度量样本 i 和 j 的特征距离
D_{ik}^s, D_{jl}^t	结构成本矩阵，干预组与对照组样本间结构距离
$L(C_{ij}, D_{ik}^s, D_{jl}^t)$	FGW 的张量损失函数
α	FGW 中平衡特征对齐与结构对齐的超参数
$\mathcal{L}_{FGW}$	Fused Gromov-Wasserstein 损失
$\mathbf{g}_{fit}, \mathbf{g}_{align}, \mathbf{g}_{rank}$	拟合、对齐、排序三个任务的梯度向量
$w_i(t)$	第 t 步时第 i 个任务的动态权重

块中，定义 $\mathbf{g}_{fit}, \mathbf{g}_{align}, \mathbf{g}_{rank}$ 分别对应因果效应拟合、分布结构对齐与增益排序三个子任务的梯度向量。这些向量的模长反映了各任务在当前训练步的优化力度。

$w_i(t)$ 表示第 t 次迭代时分配给第 i 个任务的动态权重系数，该系数由 GradNorm 算法根据任务的学习进度自适应调整，以实现多任务梯度的动态平衡。

表 4.1 汇总了上述本章新增或重新定义的主要数学符号。

4.3 GSDR 模型框架




图 4.1 GSDR 模型总体框架

GSDR (GradNorm-enhanced Structured Density Ranking) 模型是在第三章提出的 SDR 框架基础上的深度演进，旨在进一步解决复杂推荐场景下因果推断中的深层结构保留问题与多任务动态平衡挑战。图 4.1 展示了模型的总体框架。GSDR 不再局限于简单的分布对齐，而是构建了一个包含 (1) SDR 基础增益预估结构、(2) FGW 结构对齐模块和 (3) 帕累托多目标优化模块的增益模型框架。

首先，本章沿用了第三章构建的 **SDR 框架**。该结构集成了基于 Sinkhorn 算法的分布对齐模块与密度加权排序机制，已经证明了其在初步消除选择偏差和优化增益排序上的有效性。GSDR 继承了这一核心骨干，利用其强大的表征提取

能力和对高价值用户的敏感性，作为后续进行更高阶结构对齐和动态优化的基础载体。

其次，为了克服 SDR 中基础 Wasserstein 对齐可能破坏数据流形结构的问题，我们引入了 **FGW 结构对齐模块**。该模块将最优传输从“点对点”的距离度量升级为“结构对结构”的拓扑度量。通过融合 Gromov-Wasserstein 距离^[93]，模型不仅度量特征空间中的绝对距离，还显式约束了样本间相对关系的结构一致性，确保在消除选择偏差的同时，最大程度保留用户群体的内在聚类结构与语义关联。

最后，针对 SDR 框架中固定权重加权难以应对多目标动态冲突的局限，设计了 **多目标优化模块**。该模块旨在寻找多任务学习的帕累托最优解，利用 GradNorm 动态加权算法，通过自适应调整各任务的损失权重，平衡不同任务的学习节奏，避免单一任务主导训练，从而实现模型在准确性、平衡性与排序能力上的综合最优。

4.3.1 FGW-OT 结构对齐模块

在第三章中，我们使用 Wasserstein 距离来对齐特征分布^[94]。其核心思想是最小化传输成本 $\sum \pi_{ij} C_{ij}$ ，其中 $C_{ij} = \|\mathbf{z}_i^t - \mathbf{z}_j^c\|^2$ 。这种对齐方式假设特征空间是绝对的，忽略了样本间的相对几何关系。

本节旨在论证从第三章的 SDR 框架（基于 Sinkhorn-Wasserstein）向本章 GS DR 框架（基于 FGW-OT）演进的理论必要性。我们将从最优传输的拓扑性质出发，阐述仅考虑边缘分布对齐的局限性，并证明引入结构化约束对因果推断的重要性。

第三章中采用的 Wasserstein 距离旨在最小化将干预组分布 μ 变换为对照组分布 ν 的总传输成本。其优化目标为：

$$\min_{\pi \in \Pi(\mu, \nu)} \sum_{i,j} \pi_{ij} \|\mathbf{z}_i^t - \mathbf{z}_j^c\|^2. \quad (4.4)$$

尽管该方法在统计上有效地拉齐了两个域的边缘分布，但其本质上是基于“点对点”（Point-wise）成本的线性规划。在数学上，Kantorovich 问题的最优解并不

保证传输映射的连续性。这意味着，源域中两个在流形上相邻的样本 z_i, z_k ，为了最小化全局成本，可能会被映射到目标域中两个相距甚远的样本 z_j, z_l 。对于增益模型而言，这种拓扑结构的破坏是不可接受的。增益模型高度依赖于**局部平滑性假设**，即特征相似的用户应当具有相似的增益。若对齐过程仅仅为了满足分布一致性 ($P(Z|T=1) = P(Z|T=0)$) 而破坏了特征空间内部的邻域结构，将导致模型无法利用观测样本的局部信息准确外推反事实结果，从而引入不可忽视的估计偏差。

为了克服上述缺陷，本章引入 Fused Gromov-Wasserstein (FGW) 距离。与 Wasserstein 距离仅关注一阶特征距离不同，FGW 引入了二阶 Gromov-Wasserstein 项来约束样本对之间的关系保持：

$$\mathcal{L}_{GW}(\pi) = \sum_{i,j,k,l} \pi_{ij} \pi_{kl} \underbrace{|d(z_i^t, z_k^t) - d(z_j^c, z_l^c)|^2}_{\text{Structure Distortion}}. \quad (4.5)$$

该项施加了一种约束。它强制要求传输方案 π 必须保持样本间的相对几何关系：如果干预组中的样本对 (z_i, z_k) 距离较近，那么它们在对照组中的匹配对象 (z_j, z_l) 也必须保持相应的距离。

从几何视角看，FGW-OT 通过联合优化特征匹配成本与结构畸变成本在消除选择偏差的同时，最大程度地保留数据流形的拓扑结构，从而为 CATE 估计提供了更鲁棒的特征表示。

Fused Gromov-Wasserstein (FGW) 距离的优化目标定义为：

$$FGW_{\alpha, \epsilon}(\mu, \nu) = \min_{\pi \in \Pi(\mu, \nu)} \sum_{i,j,k,l} \pi_{ij} \pi_{kl} \underbrace{((1-\alpha)C_{ij} + \alpha|D_{ik}^s - D_{jl}^t|^2)}_{\text{TensorCost}} - \epsilon H(\pi). \quad (4.6)$$

其中：

- $C_{ij} = \|z_i - z_j\|^2$ ：表示特征层面的对齐成本（Feature Cost）。
- $|D_{ik}^s - D_{jl}^t|^2 = \|\|z_i - z_k\|^2 - \|z_j - z_l\|^2\|^2$ ：表示结构层面的对齐成本（Structure Cost）。它衡量了干预组内部的拓扑结构（样本对距离）与对照组内部的拓扑结构是否一致。

- $\alpha \in [0, 1]$: 平衡系数。当 $\alpha = 0$ 时退化为 Wasserstein 距离；当 $\alpha = 1$ 时退化为 Gromov-Wasserstein 距离。

由于 FGW 的目标函数中包含了关于传输矩阵 π 的二次项（即 $\pi_{ij}\pi_{kl}$ ），这使得其优化问题成为一个非凸的二次规划问题。为了高效求解该问题，在每一次迭代中，我们固定当前的传输方案 $\pi^{(k-1)}$ ，计算当前的梯度矩阵 $\mathbf{G}^{(k)}$ ，该梯度矩阵综合了固定的特征成本矩阵 $\mathbf{M}_{feat}$ 和依赖于上一轮传输方案的结构成本项。此时，原问题就退化为以 $\mathbf{G}^{(k)}$ 为成本矩阵的熵正则化最优传输问题，随后便可直接利用高效的 Sinkhorn 算法进行更新。通过不断交替更新梯度矩阵与传输方案，算法最终收敛至局部最优解，具体流程如算法 4.3.1 所示

算法 4.3.1: FGW-OT 距离计算与最优传输求解

Input: 干预组特征 $\mathbf{Z}_t$, 对照组特征 $\mathbf{Z}_c$, 平衡系数 α , 正则化系数 ϵ , 迭代次数 K

Output: 最优传输方案 π^* , FGW 损失 $\mathcal{L}_{FGW}$

01: **步骤 1: 初始化成本矩阵与传输方案**

02: $\mathbf{M}_{feat} = \text{dist}(\mathbf{Z}_t, \mathbf{Z}_c)$ // 计算特征距离矩阵

03: $\mathbf{D}_t = \text{dist}(\mathbf{Z}_t, \mathbf{Z}_t)$, $\mathbf{D}_c = \text{dist}(\mathbf{Z}_c, \mathbf{Z}_c)$ // 计算组内结构距离矩阵

04: $\pi^{(0)} = \mathbf{1}_{n_t} \mathbf{1}_{n_c}^T / (n_t n_c)$ // 初始化均匀分布传输方案

05: **步骤 2: Sinkhorn 迭代求解 FGW**

06: **for** $k = 1$ to K **do**

07: $\mathbf{G}^{(k)} = (1 - \alpha)\mathbf{M}_{feat} + \alpha\mathcal{L}(\mathbf{D}_t, \mathbf{D}_c) \otimes \pi^{(k-1)}$ // 计算梯度项

08: $\mathbf{K}^{(k)} = \exp(-\mathbf{G}^{(k)} / \epsilon)$

09: $\mathbf{u}^{(k)} = \mathbf{1}_{n_t} \oslash (\mathbf{K}^{(k)} \mathbf{v}^{(k-1)})$ // 更新对偶变量 $\mathbf{u}$

10: $\mathbf{v}^{(k)} = \mathbf{1}_{n_c} \oslash (\mathbf{K}^{(k)T} \mathbf{u}^{(k)})$ // 更新对偶变量 $\mathbf{v}$

11: $\pi^{(k)} = \text{diag}(\mathbf{u}^{(k)}) \mathbf{K}^{(k)} \text{diag}(\mathbf{v}^{(k)})$ // 更新传输方案

12: **end for**

13: **步骤 3: 计算最终损失**

14: $\mathcal{L}_{FGW} = \sum_{i,j} \pi_{ij}^{(K)} \mathbf{G}_{ij}^{(K)}$

15: **return** $\pi^{(K)}, \mathcal{L}_{FGW}$

4.3.2 基于 GradNorm 的多目标梯度平衡策略

在增益模型中，我们需要同时最小化三个损失函数： $\mathcal{L}_{fit}$ 、 $\mathcal{L}_{FGW}$ 和 $\mathcal{L}_{rank}$ 。这三个目标之间往往存在冲突，特别是对排序精度的影响尤为严重。例如，过度追求 $\mathcal{L}_{FGW}$ 最小化可能会扭曲特征空间，导致 $\mathcal{L}_{fit}$ 上升。更关键的是，不同损失函数的量级和梯度模长差异巨大，排序任务往往因为梯度微弱而被主导任务（对齐任务）所抑制，这直接导致了挑战二（排序学习缺失导致的模型排序性能瓶颈）在复杂模型中难以被攻克。

为了平衡各个任务的学习速率，寻找帕累托最优解，我们采用 GradNorm (Gradient Normalization) 算法。GradNorm 是一种自适应的多任务学习优化策略，它通过动态调整每个任务的损失权重 $w_i(t)$ ，使得不同任务的梯度模长在训练过程中保持相对一致的量级，从而让所有任务以相近的速度进行学习，确保排序目标能够被有效优化。

设 θ 为共享编码器的参数， $G_i(t) = \|\nabla_{\theta} w_i(t) \mathcal{L}_i(t)\|_2$ 为第 t 步时第 i 个任务的加权梯度模长。GradNorm 的核心目标是最小化以下损失函数来更新权重 $w_i(t)$:

$$\mathcal{L}_{grad}(t) = \sum_i |G_i(t) - \bar{G}(t) \times [r_i(t)]^\beta|_1. \quad (4.7)$$

传统的增益模型模型（如 DragonNet）通常采用固定权重的线性加权求和 $\mathcal{L}_{total} = \sum w_i \mathcal{L}_i$ 。这种方法隐含了一个强假设：各个子任务的学习难度和收敛速度是同步的。然而，在实际训练中，这一假设往往不成立，在第三章提出的 SDR 训练时表现为以下两类问题：

- **对齐任务的过快**：分布对齐损失（ $\mathcal{L}_{FGW}$ ）通常在训练初期下降极快。如果权重固定，巨大的对齐梯度会迫使编码器迅速将特征压缩到一个低维流形上，导致特征表达能力过早丧失，后续的拟合任务难以在“塌缩”的特征空间中找到最优解。
- **排序任务被抑制**：排序损失（ $\mathcal{L}_{rank}$ ）通常涉及复杂的组合优化，梯度信号较为稀疏且嘈杂。在静态权重下，排序任务往往被拟合任务和对齐任务所主导，导致模型虽然 MSE 很低且分布对齐良好，但 AUUC 指标（即业务

排序能力)提升缓慢,无法真正解决排序精度问题。

GradNorm 通过实时监控相对反向训练速率 $r_i(t)$, 构建了一个闭环反馈系统:

$$w_i(t+1) \leftarrow w_i(t) - \eta \nabla_{w_i} \mathcal{L}_{grad}. \quad (4.8)$$

- 当对齐任务梯度下降过快时 (r_{align} 较小), GradNorm 会自动降低其权重 w_{align} , 防止其过度主导。
- 当排序任务梯度下降过慢时 (r_{rank} 较大), GradNorm 会提升其权重 w_{rank} , 为其注入更大的梯度能量。

这种机制确保了三个任务始终处于“齐头并进”的状态,使得模型最终能够收敛到帕累托前沿上一个各方面性能均衡的最优点,而非仅仅在某一个容易优化的单目标上过拟合。

GradNorm 算法的核心思想是通过动态调整损失权重 $w_i(t)$, 使得各个任务的梯度模长 $G_i(t)$ 趋向于一个共同的基准 $\bar{G}(t)$, 同时考虑到各个任务的学习进度 $r_i(t)$ 。

具体而言, 梯度模长 $G_i(t)$ 定义为加权损失对共享参数 θ 的梯度范数:

$$G_i(t) = \|\nabla_{\theta}(w_i(t)\mathcal{L}_i(t))\|_2 = w_i(t)\|\nabla_{\theta}\mathcal{L}_i(t)\|_2. \quad (4.9)$$

注意, 这里 $G_i(t)$ 是权重 $w_i(t)$ 的函数。

为了平衡学习速率, 我们定义每个任务的目标梯度模长 $G_i^*(t)$ 为:

$$G_i^*(t) = \bar{G}(t) \times [r_i(t)]^\beta. \quad (4.10)$$

其中 $\bar{G}(t) = \frac{1}{T} \sum_j G_j(t)$ 是当前所有任务梯度模长的均值, $r_i(t)$ 是相对反向训练速率, β 是恢复力度超参数。

GradNorm 的损失函数 $\mathcal{L}_{grad}$ 衡量了实际梯度模长与目标梯度模长之间的差异:

$$\mathcal{L}_{grad}(t; w_i(t)) = \sum_i |G_i(t) - G_i^*(t)|_1. \quad (4.11)$$

在每一步训练中，我们不仅更新模型参数 θ 以最小化主任务损失 $\sum w_i \mathcal{L}_i$ ，同时更新权重 w_i 以最小化 $\mathcal{L}_{grad}$ 。通常，权重更新使用独立的优化器（如标准 SGD），并且在更新后进行归一化处理（ $\sum w_i = T$ ），以防止权重整体爆炸或消失。

4.3.3 损失函数与训练算法

GSDR 模型的训练过程是一个多任务协同优化的过程。最终的总损失函数 $\mathcal{L}_{total}$ 由反事实预测损失、FGW 结构对齐损失以及密度加权排序损失三部分组成，并由 GradNorm 动态权重 $w_i(t)$ 进行加权求和：

$$\mathcal{L}_{total}(\theta, t) = w_{fit}(t)\mathcal{L}_{fit}(\theta) + w_{align}(t)\mathcal{L}_{FGW}(\theta) + w_{rank}(t)\mathcal{L}_{rank}(\theta) + \lambda_{reg}\|\theta\|_2^2. \quad (4.12)$$

其中， $\mathcal{L}_{fit}$ 负责保证因果效应的拟合精度， $\mathcal{L}_{FGW}$ 负责在消除选择偏差的同时保留特征的几何结构， $\mathcal{L}_{rank}$ 则直接优化业务关心的增益排序能力。 λ_{reg} 为正则化系数，用于防止过拟合。

为了实现上述多目标的高效协同训练，我们设计了如下的端到端训练算法。该算法集成了 Sinkhorn 迭代以计算 FGW 距离，并内嵌了 GradNorm 优化步以实时调整任务权重，确保各任务以平衡的速率收敛。

4.4 实验与分析

为了全面且深入地评估所提出的 GSDR 框架在处理结构化分布对齐及多任务协同优化方面的有效性，本节在包含真实业务场景与半合成反事实场景的多个基准数据集上开展了广泛的实证研究。具体的实验设计旨在回答以下三个核心研究问题：

- **研究问题一：**与最先进的（SOTA）方法特别是本论文第三章提出的 SDR 框架相比，GSDR 在估计准确性（如 PEHE, ATE）与排序能力（如 AUUC）方面是否取得了进一步的突破？

- **研究问题二：**引入 Fused Gromov-Wasserstein (FGW) 最优传输约束是否有效地在潜在表示空间中捕捉并对齐了样本的内在几何拓扑结构？
- **研究问题三：**GSDR 中的各个创新组件（FGW 结构对齐、GradNorm 动态加权）是否都对提升模型的整体性能做出了实质性贡献？
- **研究问题四：**关键超参数（如结构权重 κ 、恢复力度 α ）如何影响 GSDR 的性能？

4.4.1 实验设置

(1) 数据集设置。为了保持实验的一致性与可比性，本章采用与第三章完全一致的三个数据集及其预处理方式：

- **Hillstrom-Man & Hillstrom-Woman:** 源自真实的电子邮件营销场景，分别包含男性与女性用户数据，用于评估模型在真实业务环境下的排序能力。
- **MovieLens-100K 数据集:** 基于电影评分数据构建的半合成数据集，包含完整的事实与反事实结果，用于精确评估因果效应的拟合误差。

关于上述数据集的具体统计信息、特征维度及反事实结果生成逻辑，请参阅第三章第 3.5.1 节。

(2) 基线模型。我们将 GSDR 与以下三类主流增益模型进行对比，涵盖了统计方法、匹配方法和表征学习方法。此外，我们将第三章提出的 **SDR** 作为最强基线纳入比较，以验证进阶模块的有效性。

- **统计估计算法:** OLS, R.Forest, S-Learner, T-Learner, TarNet.
- **匹配估计算法:** C.Forest, O.Forest.
- **表征学习估计算法:** CFR-MMD, CFR-WASS, ESCFR.

此外，为了验证本章进阶模块的有效性，我们将第三章提出的 **SDR** 模型作为最强基线纳入比较。通过与 SDR 的直接对比，我们可以量化评估引入 FGW 结构对齐与 GradNorm 动态优化所带来的性能增益。

4.4.2 结果与分析

(1) CATE 估计准确性分析。首先，我们在 MovieLens-100K 数据集上评估模型对个体因果效应（CATE）的估计准确性^[95]。表 4.2 展示了各模型在训练集和测试集上的 ϵ_{PEHE} 和 ϵ_{ATE} 指标（研究问题一）。

表 4.2 GSDR 模型与基线模型的 CATE 估计准确性指标对比

Mode	In-Sample			Out-of-Sample		
	$\epsilon_{PEHE} \downarrow$	$\epsilon_{ATE} \downarrow$	$\epsilon_{ATT} \downarrow$	$\epsilon_{PEHE} \downarrow$	$\epsilon_{ATE} \downarrow$	$\epsilon_{ATT} \downarrow$
OLS	0.6275	0.4151	0.2883	0.6350	0.4216	0.2923
R.Forst	0.5331	0.2505	0.3772	0.5339	0.244	0.3733
S.Learner	0.5225	0.2125	0.0854	0.5297	0.2199	0.0893
T.Learner	0.6063	0.2194	0.1055	0.6691	0.2519	0.1281
TarNet	0.5422	0.2694	0.1427	0.5492	0.2759	0.1466
C.Forest	0.5143	0.1862	0.3164	0.5166	0.1780	0.3099
O.Forest	0.5357	0.1969	0.0734	0.5440	0.1960	0.0730
CFR - MMD	0.5411	0.1957	0.0712	0.5539	0.2081	0.0800
CFR - WASS	0.5328	0.1598	0.0438	0.5469	0.1662	0.0499
ESCFR	0.5094	0.2003	0.0772	0.5202	0.2037	0.0776
SDR	0.4832	0.1496	0.0282	0.4935	0.1544	0.0291
GSDR	0.4747	0.0625	0.0225	0.4798	0.0689	0.0208

表 4.2 详细列出了各模型在训练集（In-Sample）和测试集（Out-of-Sample）上的 ϵ_{PEHE} 、 ϵ_{ATE} 以及 ϵ_{ATT} 表现。数据表明，GSDR 在所有准确性指标上均显著优于对比基线，且全面超越了第三章提出的 SDR 模型。在 Out-of-Sample 测试中，GSDR 的个体级因果效应误差 ϵ_{PEHE} 降至 0.4798，相较于基础框架 SDR (0.4935) 降低了约 **2.8%**。更令人瞩目的是，在衡量全局平均效应的 ϵ_{ATE} 指标上，GSDR 仅为 0.0689，相比 SDR (0.1544) 实现了 **55.4%** 的惊人误差缩减。这一结果有力地证明了 FGW 结构化对齐的优越性：传统的 Wasserstein 距离（SDR 所采用）仅关注点对点的概率质量传输，可能破坏特征流形的局部几何结构；而 FGW 距离通过引入 Gromov-Wasserstein 项，强制要求对齐后的特征保持原始空间的拓扑结构，从而使得相似的样本在潜在空间中依然相邻。这种“结构保真”

的特性极大地减少了因果效应推断中的偏差，特别是在 ATE 这种全局指标上体现得尤为明显。

(2) 模型排序能力分析。为了验证模型在实际业务中的决策价值，我们在 Hillstrom-Man、Hillstrom-Woman 及 MovieLens-100K 数据集上评估了增益模型排序性能。表 4.3 展示了各模型在 AUUC、AUQC 和 LIFT@100 指标上的表现。

表 4.3 GSDR 模型与基线模型的增益排序指标对比

Dataset	Hillstrom-Man			Hillstrom-Woman			MovieLens-100K		
Metric	AUUC↑	AUQC↑	LIFT@100↑	AUUC↑	AUQC↑	LIFT@100↑	AUUC↑	AUQC↑	LIFT@100↑
OLS	0.3665	0.2669	-2.8228	0.0863	0.2600	0.2240	0.5013	0.3304	0.2800
R.Forst	0.4148	0.2991	-0.9502	0.4272	0.2324	1.3317	0.4832	0.3238	0.2000
S.Learner	0.3550	0.2770	0.4496	0.2294	0.2314	-2.5451	0.5257	0.3507	0.2000
T.Learner	0.4210	0.3127	-3.9439	0.3342	0.1768	-2.9667	0.4989	0.3466	0.4000
TarNet	0.4543	0.3219	0.5823	0.2073	0.1648	1.2447	0.5048	0.3374	0.3200
C.Forest	0.3920	0.2691	0.7856	0.3652	0.2302	-0.5261	0.5305	0.3432	0.3000
O.Forest	0.4820	0.3125	0.7247	0.3904	0.2806	-0.6381	0.5309	0.3517	0.2300
CFR-MMD	0.4633	0.3147	-0.4554	0.2246	0.1571	1.2313	0.6069	0.3917	0.3600
CFR-WASS	0.4702	0.3184	0.6701	0.3545	0.2923	-0.7702	0.6187	0.3953	0.3800
ESCFR	0.4631	0.3326	0.7258	0.3575	0.2668	1.5103	0.6233	0.3985	0.4200
SDR	0.5863	0.3871	1.1742	0.7121	0.4406	3.1399	0.6296	0.3956	0.4700
GSDR	0.6524	0.4104	2.7079	0.7413	0.4715	3.2650	0.67145	0.41689	0.4800

实验结果表明，GSDR 在三个数据集上均取得了最优的排序效果，实现了对 SDR 的进一步超越。以 Hillstrom-Man 数据集为例，GSDR 的 AUUC 达到 0.6524，相比于 SDR (0.5863) 提升了约 **11.3%**；在衡量头部高价值用户转化的 LIFT@100 指标上，GSDR 更是高达 2.7079，远超 SDR 的 1.1742。这一显著的优势在 Hillstrom-Woman 数据集上同样得到了验证，GSDR 将 AUUC 进一步推高至 0.7413。GSDR 之所以能在排序能力上取得如此突破，主要归功于 GradNorm 动态多任务优化机制。在 SDR 中，排序损失往往因为梯度稀疏或量级较小而被拟合损失所掩盖；而 GradNorm 通过实时平衡各任务的梯度流，确保了排序任务在整个训练过程中始终获得足够的关注，从而使模型能够敏锐地捕捉到那些细微但关键的增益排序信号。

4.4.3 FGW 结构对齐的几何可视化分析

为了深入探究 GSDR 框架中 Fused Gromov-Wasserstein (FGW) 约束在真实高维特征空间中的拓扑保持能力, 本节设计了一项几何可视化实验 (研究问题二)。为了直观展示高维样本在潜在表示空间 (Latent Representation Space) 中的分布对齐情况, 本实验将高维特征投影至二维平面, 重点考察模型在消除干预组 (Treated) 与对照组 (Control) 分布偏差时, 是否能够维持用户群体的局部邻域结构与全局拓扑一致性。

图 4.2 直观展示了基于 Sinkhorn 算法 (SDR 采用) 与基于 FGW 算法 (GSDR 采用) 推导出的最优传输耦合矩阵 π^* 的可视化结果。图中蓝色 “+” 与红色 “×” 分别代表降维后的干预组与对照组用户样本, 连接了最优传输耦合矩阵中具有显著传输权重的样本对。




图 4.2 特征空间上的对齐效果对比

从图 4.2a 的结果可以看出, 经典的 Sinkhorn 算法在处理具有复杂结构的真实用户数据时存在本质局限。由于 Wasserstein 距离的优化目标仅由一阶欧氏距离成本 $\|\mathbf{x}_i - \mathbf{y}_j\|^2$ 驱动, 其倾向于寻找全局传输代价最小的方案, 而忽略了样本间的二阶关系约束。为了满足边缘分布的对齐, 算法强制将干预组中具有相似特征的用户群体映射到对照组中特征截然不同的区域, 具体表现为如图中大量交叉错乱的连线。在因果推断的语境下, 这意味着模型可能会错误地将具有

截然不同潜在特征的用户视为反事实近邻，从而引入显著的条件偏差。

相比之下,图 4.2b 证实了引入 FGW 约束的必要性与有效性。得益于 Gromov-Wasserstein 项对**成对距离矩阵 (Pairwise Distance Matrix)** 的等距同构约束,GSDR 在优化过程中显式地惩罚了破坏局部拓扑结构的传输方案。如图所示,FGW 成功地在对齐过程中“锁定”了用户群体的聚类特征,实现了簇到簇的精确映射。这种对齐方式不仅消除了分布差异,更重要的是在潜在空间中保持了拓扑一致性,确保了反事实推理是建立在特征语义与几何结构双重相似的基础之上。这一发现有力地支撑了本章的核心论点:即在复杂真实的业务场景下,结构化的最优传输是提升因果效应估计鲁棒性的关键所在。

4.4.4 消融实验

为了系统性地解构 GSDR 框架中两个核心创新组件——FGW 结构对齐与 GradNorm 动态优化的贡献,我们在 Hillstrom-Man 数据集上开展了深入的消融研究(研究问题三)。我们构建了四个具有不同配置的变体模型,以第三章提出的 SDR 为基线(Base),逐步引入 FGW 和 GradNorm 模块,并对比它们在 In-Sample(训练集)与 Out-of-Sample(测试集)上的性能表现。具体实验结果汇总于表 4.4。基于实验数据,我们可以得出以下结论:

表 4.4 SDR 在 Hillstrom-Man 数据集上的消融实验结果

Components		In-Sample			Out-of-Sample		
FGW	GradNorm	AUUC↑	AUQC↑	LIFT@100↑	AUUC↑	AUQC↑	LIFT@100↑
×	×	0.6697	0.4018	0.7889	0.5863	0.3871	1.1742
×	✓	0.7062	0.4473	2.7996	0.6001	0.3874	2.0146
✓	×	0.7087	0.4618	3.0889	0.6313	0.3919	2.6578
✓	✓	0.8024	0.5031	3.7079	0.6524	0.4104	2.7079

FGW 结构对齐显著增强了特征泛化能力。对比第一行(Base/SDR)与第三行(Only FGW),在将对齐方式从普通的 Wasserstein 距离升级为 Fused Gromov-Wasserstein 距离后,模型在 Out-of-Sample 测试集上的 AUUC 从 0.5863 提升至 0.6313,涨幅达到 **7.7%**。同时,LIFT@100 也从 1.1742 大幅提升至 2.6578。这

一结果强有力地证明，单纯的分布对齐（如 SDR）虽然能消除全局偏差，但可能会扭曲特征空间中的局部邻域关系。FGW 通过同时约束样本间的距离和结构，确保了对齐后的特征流形在几何上是保真的，从而使得模型在面对未见数据时具有更强的鲁棒性和泛化能力。

GradNorm 动态优化有效缓解了多任务冲突。对比第一行（Base/SDR）与第二行（Only GradNorm），仅引入 GradNorm 动态权重调整机制也能带来明显的性能增益。Out-of-Sample 的 AUUC 提升至 0.6001，相比基线提升了约 **2.4%**。更重要的是，LIFT@100 指标接近翻倍（从 1.1742 升至 2.0146）。这表明，在多任务学习中，固定的权重分配往往会导致某些任务（特别是难度较大的排序任务）被忽略。GradNorm 通过平衡梯度流，成功地“激活”了排序任务的学习，使其在不牺牲其他任务性能的前提下，显著改善了高价值用户的识别能力。

表中第四行（GSDR）的结果显示，当同时集成 FGW 与 GradNorm 时，模型实现了最优性能。Out-of-Sample 的 AUUC 攀升至 0.6524，总体提升幅度达 **11.3%**。这体现了两个模块良好的协同效应：FGW 构建了一个结构良好的特征空间，而 GradNorm 则确保了在这个优质空间上的优化过程是平衡且高效的，两者相辅相成，共同推动了模型性能的飞跃。

4.4.5 超参数敏感性分析

为了评估 GSDR 模型对关键超参数的鲁棒性并确定最佳参数配置，我们在 Hillstrom-Man 数据集上进行了超参数敏感性分析（研究问题四）。本节重点考察两个核心超参数：FGW 平衡系数 κ 和 GradNorm 恢复力度 α 。图 4.3 展示了不同参数取值下模型在 AUUC、AUQC 和 LIFT@100 三个指标上的性能变化趋势。

FGW 平衡系数 κ 。参数 κ 调节了 FGW 距离中特征成本（Feature Cost）与结构成本（Structure Cost）之间的权衡，即 $(1 - \kappa)C_{feat} + \kappa C_{struc}$ 。如图 4.3 (a)-(c) 所示，随着 κ 的增加，各项性能指标呈现出先升后降的倒 U 型趋势：当 κ 过小（如 < 0.01 ）时，模型退化为主要依赖特征值的点对点匹配，忽略了特征空间中的拓扑结构，导致对齐效果有限；当 κ 适中（在 0.01 至 0.1 之间）时，AUUC 指标达到峰值，说明引入适量的结构约束有助于模型捕捉更本质的分布相似性；然




图 4.3 GSDR 模型性能指标随超参数变化的趋势分析

而，当 κ 过大（如 > 0.5 ）时，结构成本主导了优化目标，模型过度强求几何形状的一致性而牺牲了对特征内容的匹配，反而损害了因果推断的准确性。因此，我们在实验中设定 $\kappa = 0.05$ 。

GradNorm 恢复力度 α 。 参数 α 控制了 GradNorm 对梯度模长的修正力度，决定了模型对“落后”任务的关注程度。如图 4.3 (d)-(f) 所示，同样呈现出明显的倒 U 型趋势：当 α 较小（如 < 0.1 ）时，权重调整过于保守，难以有效扭转多任务间的不平衡状态，排序任务依然未能获得足够的梯度支持；随着 α 增加至 0.5 左右，模型性能达到最佳，这表明适度的恢复力度能够为弱势任务提供恰到好处的梯度补偿，使各任务齐头并进；但当 α 过大（如 > 1.0 ）时，权重的波动变得剧烈，引入了过多的训练噪声，导致优化过程不稳定，性能随之下降。基于此，我们将 α 设定为 0.5 以实现最佳的动态平衡。

4.5 本章小结

本章在第三章 SDR 的基础上，进一步提出了结构感知的进阶框架 GSDR。针对基础框架忽略局部几何结构和多目标冲突的问题，我们引入了 Fused Gromov-Wasserstein 距离和基于梯度的多目标优化算法。在 Hillstrom-man、Hillstrom-woman 和 MovieLens-100K 数据集上的实验证明，GSDR 能够更深层次地挖掘

数据结构信息，并更稳健地平衡拟合、对齐与排序目标，从而实现了增益模型性能的全面提升。

第5章 总结与展望

本章进行全文的总结与展望工作，首先对本文研究进行全面总结，梳理本文研究脉络与关键贡献；接下来对未来工作进行展望，分析增益模型在复杂场景下的未来发展方向。

5.1 本文研究总结

增益模型作为智能营销与广告投放的核心技术，其精准性直接影响企业营销资源的配置效率与长期收益。本文深入剖析了现有增益模型在复杂业务场景下面临的两大核心挑战：观测数据分布偏差导致的增益效应估计偏倚（挑战一），以及排序学习缺失与长尾分布干扰导致的增益排序性能受限（挑战二）。针对上述问题，本研究通过引入最优传输理论实现组间分布的对齐，有效解决了观测数据分布偏差导致的增益效应估计偏倚，创新性地提出了基于样本密度加权的排序损失，并引入多目标梯度平衡策略，提升了增益模型的排序能力，构建了能够协同分布对齐、响应拟合与排序学习的统一框架，主要研究成果总结如下：

（1）针对“观测数据分布偏差导致的因果效应估计偏倚”这一挑战（挑战一），本文提出了一套从特征边缘分布到几何拓扑结构的分布对齐方案，有效消除了选择偏差。首先，在第三章中，针对干预组与对照组的特征分布差异，本文提出了基于 Sinkhorn 与样本密度排序的增益模型（SDR）。该模型引入最优传输理论，利用 Sinkhorn 算法高效求解 Wasserstein 距离，强制拉齐干预组与对照组的特征分布，在潜在表示空间构建了无偏的特征环境，解决了传统方法在高维空间去偏困难的问题。进一步地，在第四章中，针对基础对齐忽略数据流形结构的问题，本文提出了 GradNorm 增强的结构化排序增益模型（GSDR）。该模型引入 Fused Gromov-Wasserstein (FGW) 距离，通过联合优化特征匹配成本与结构畸变成本，实现了“特征与结构”的双重对齐。这种方法不仅保证了边缘分布的一致性，还保留了用户群体的局部拓扑结构，实现了更深层次的结构化去偏，显著提升了模型在复杂分布下的泛化能力。

（2）针对“排序学习缺失与长尾分布干扰导致的增益排序性能受限”这一

挑战（挑战二），本文构建了从静态加权排序到动态多目标协同优化的鲁棒学习体系。首先，在第三章中，针对传统 MSE 损失无法直接优化排序且易受长尾噪声主导的问题，SDR 模型设计了密度加权成对排序损失。通过高斯核密度估计量化样本稀疏度，降低极端值的梯度权重，引导模型聚焦于主体样本的相对次序学习，直接解决了“拟合准不等于排得准”的难题。在此基础上，在第四章中，针对引入强力对齐约束后排序任务梯度被抑制的问题，GSDR 模型引入了 GradNorm 动态优化算法。该算法实时监控多任务的梯度模长与学习速率，自适应调整拟合、对齐与排序任务的损失权重。它有效地解决了多目标冲突问题，确保排序目标在复杂的训练过程中始终得到有效优化，从而在复杂多变的业务场景下实现了增益排序性能的稳健提升。

本研究从理论、方法和技术三个层面推动了增益模型研究的发展。理论层面，建立了基于最优传输的因果推断分布对齐框架，拓展了结构化对齐在增益建模中的应用边界；方法层面，提出的基于样本密度加权的排序策略与动态多目标优化方法，为解决排序学习中的长尾干扰与任务冲突提供了新的方法；技术层面，所提算法在多个公开基准数据集上均取得了显著优于 SOTA 的性能，为构建精准可靠的智能营销系统提供了坚实的实践范式。

5.2 未来工作展望

面向增益模型在复杂业务场景中的深化应用与前沿技术演进，未来的研究工作将重点聚焦于以下三个具有挑战性与高价值的方向：

（1）构建多处理（Multi-Treatment）与连续处理（Continuous Treatment）效应估计体系。现有的 S/T/X-Learner 等主流框架大多局限于二元干预（Treatment/Control）场景，难以高效处理现实中普遍存在的多离散干预（如多种优惠券组合）或连续型干预（如折扣力度、广告时长）。在这些场景下，传统的逐一建模方法不仅面临严重的“维度灾难”，且无法捕捉干预之间的交互效应与边际递减效应。未来的研究应致力于开发适配连续处理空间的因果树模型（如 Generalized Causal Trees）或基于注意力机制的深度网络，实现对剂量-反应曲线

(Dose-Response Curve) 的精准拟合; 同时, 探索多处理任务间的平衡表征学习机制与联合损失函数, 在统一的框架下实现对多种干预手段异质性效应的无偏估计与全局最优分配。

(2) 构建动态时序增益模型。 现有模型通常建立在静态环境与个体独立性假设之上, 忽略了用户行为的时序依赖性与群体间的溢出效应。然而, 在真实的营销链路中, 用户的转化往往受历史干预序列的累积影响, 且在社交电商场景中, 对一个用户的干预可能会波及周边节点的行为。未来的工作需要融合 Transformer 或 LSTM 等时序架构, 构建能够捕捉长短期因果依赖的动态增益模型, 实现从单次转化优化向全生命周期价值 (LTV) 最大化的范式转换; 同时, 结合图神经网络 (GNN) 量化网络干扰效应, 将溢出偏差纳入因果损失函数进行修正, 从而在具有强社交属性的复杂网络环境中实现更精准的全局资源配置。

(3) 探索大语言模型 (LLM) 与增益模型的深度融合范式。 生成式人工智能的爆发为因果推断带来了新的契机。LLM 强大的世界知识与逻辑推理能力, 有望解决传统统计方法难以处理的“未观测混淆因子”与“反事实数据缺失”难题。未来的研究可以利用 LLM 辅助构建领域特定的因果图 (Causal Graph), 利用其先验知识识别潜在的混淆路径; 同时, 探索基于 LLM 的生成式反事实增强技术, 将其作为“用户模拟器”生成高质量的反事实样本, 缓解稀疏数据下的训练困难。更进一步, 可以研发基于 LLM Agent 的交互式决策系统, 将增益预测能力内化为 Agent 的规划模块, 实现从“被动预测”到“主动干预决策”的智能化跨越。

参考文献

- [1] Gutierrez P, Gérardy J-Y. Causal inference and uplift modelling: A review of the literature[A]. International conference on predictive applications and APIs[C]. 2017: 1–13.
- [2] Radcliffe N J, Surry P D. Real-world uplift modelling with significance-based uplift trees[J]. White Paper TR-2011-1, Stochastic Solutions, 2011: 1–33.
- [3] 赵靓, 高龙, 郭苏娴, et al. Uplift 算法在商业银行智能营销体系中的应用研究[J]. 金融科技时代, 2024, 32(11): 15–23.
- [4] Radcliffe N. Using control groups to target on predicted lift: Building and assessing uplift model[J]. Direct Marketing Analytics Journal, 2007: 14–21.
- [5] Shalit U, Johansson F D, Sontag D. Estimating individual treatment effect: generalization bounds and algorithms[A]. Proceedings of the 34th International Conference on Machine Learning[C]: Vol 70. 2017: 3076–3085.
- [6] Li H, Zheng C, Wu P, et al. Who should be given incentives? counterfactual optimal treatment regimes learning for recommendation[A]. Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining[C]. 2023: 1235–1247.
- [7] Wu L, Hu D, Hong L, et al. Turning Clicks into Purchases: Revenue Optimization for Product Search in E-Commerce[A]. Proceedings of the 41st International ACM SIGIR Conference on Research and Development in Information Retrieval[C]. 2018: 365–374.
- [8] Sharma A, Hofman J M, Watts D J. Estimating the causal impact of recommendation systems from observational data[A]. Proceedings of the Sixteenth ACM Conference on Economics and Computation[C]. 2015: 453–470.
- [9] Johansson F, Shalit U, Sontag D. Learning Representations for Counterfactual Inference[A]. Proceedings of the 33rd International Conference on Machine Learning[C]: Vol 48. 2016: 3020–3029.

- [10] Goldenberg D, Albert J, Bernardi L, et al. Free lunch! retrospective uplift modeling for dynamic promotions recommendation within roi constraints[A]. Proceedings of the 14th ACM Conference on Recommender Systems[C]. 2020 : 486–491.
- [11] Künzel S R, Sekhon J S, Bickel P J, et al. Metalearners for estimating heterogeneous treatment effects using machine learning[J]. Proc. Natl. Acad. Sci. U. S. A., 2019, 116(10): 4156–4165.
- [12] He B, Weng Y, Tang X, et al. Rankability-enhanced Revenue Uplift Modeling Framework for Online Marketing[A]. Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining[C]. 2024 : 5093–5104.
- [13] 杨定川, 罗健洲, 魏轲. 对最优传输中 Sinkhorn 和 Greenkhorn 算法复杂度分析的改进 [J]. 运筹学学报 (中英文), : 1–23.
- [14] 张思京, 李福雨, 乔晓澍, et al. 基于类条件最优传输的跨域样本选择策略 [J]. 计算机应用, 2025, 45(S1): 56–59.
- [15] 曹杰彰, 莫朗元, 杜卿, et al. 基于最优传输理论的联合分布匹配方法及应用 [J]. 计算机学报, 2021, 44(6): 1233–1245.
- [16] Guelman L, Guillén M, Pérez-Marín A M. A decision support framework to implement optimal personalized marketing interventions[J]. Decision Support Systems, 2015, 72 : 24–32.
- [17] Gordon B R, Zettelmeyer F, Bhargava N, et al. A comparison of approaches to advertising measurement: Evidence from big field experiments at Facebook[J]. Marketing Science, 2019, 38(2): 193–225.
- [18] Chen J, Dong H, Wang X, et al. Bias and Debias in Recommender System: A Survey and Future Directions[J]. ACM Trans. Inf. Syst., 2023, 41(3).
- [19] Zhang W, Li J, Liu L. A Unified Survey of Treatment Effect Heterogeneity Modelling and Uplift Modelling[J]. ACM Comput. Surv., 2021, 54.
- [20] Varian H R. Causal inference in economics and marketing[J]. Proceedings of the National Academy of Sciences, 2016, 113(27): 7310–7315.

- [21] Yamane I, Yger F, Atif J, et al. Uplift modeling from separate labels[J]. Advances in Neural Information Processing Systems, 2018, 31.
- [22] Jaskowski M, Jaroszewicz S. Uplift modeling for clinical trial data[A]. Proceedings of the International Conference on Machine Learning Workshop on Clinical Data Analysis[C]: Vol 46. 2012: 79–95.
- [23] 李俊霖, 周志强. 主流因果效应估计方法的比较分析 [J]. 兰州财经大学学报, : 1–16.
- [24] Wager S, Athey S. Estimation and Inference of Heterogeneous Treatment Effects using Random Forests[J]. Journal of the American Statistical Association, 2018, 113(523): 1228–1242.
- [25] Liang D, Krishnan R G, Hoffman M D, et al. Variational autoencoders for collaborative filtering[A]. Proceedings of The Web Conference 2018[C]. 2018: 689–698.
- [26] Kingma D P. Auto-encoding variational bayes[J]. arXiv preprint arXiv:1312.6114, 2013.
- [27] Ma X, Zhao L, Huang G, et al. Entire Space Multi-Task Model: An Effective Approach for Estimating Post-Click Conversion Rate[A]. The 41st International ACM SIGIR Conference on Research & Development in Information Retrieval[C]. 2018: 1137–1140.
- [28] Chang C-Y, Tang X, Yuan B, et al. AutoConjunction: Adaptive Model-based Feature Conjunction for CTR Prediction[J]. 2020 21st IEEE International Conference on Mobile Data Management (MDM), 2020: 202–209.
- [29] Liu Y, Cao X, Yu Y. Are You Influenced by Others When Rating? Improve Rating Prediction by Conformity Modeling[A]. Proceedings of the 10th ACM Conference on Recommender Systems[C]. 2016: 269–272.
- [30] Wu L, Quan C, Li C, et al. A Context-Aware User-Item Representation Learning for Item Recommendation[J]. ACM Trans. Inf. Syst., 2019, 37(2).

- [31] Gretton A, Borgwardt K M, Rasch M J, et al. A kernel two-sample test[J]. J. Mach. Learn. Res., 2012, 13 : 723 – 773.
- [32] Cuturi M, Doucet A. Fast computation of Wasserstein barycenters[A]. Proceedings of The 31st International Conference on Machine Learning[C]. 2014 : 685 – 693.
- [33] Shi C, Blei D, Veitch V. Adapting neural networks for the estimation of treatment effects[A]. Advances in Neural Information Processing Systems[C] : Vol 32. 2019 : 2507 – 2517.
- [34] 张大操, 张琨, 吴乐, et al. 针对情境感知的自然语言的因果去偏推理方法 [J]. 计算机研究与发展, 2023, 60(08) : 1768 – 1779.
- [35] 杨新新, 刘真, 卢思博, et al. 基于因果推断的推荐系统去偏研究综述 [J]. 计算机学报, 2024, 47(10) : 2307 – 2332.
- [36] ROSENBAUM P R, RUBIN D B. The central role of the propensity score in observational studies for causal effects[J]. Biometrika, 1983, 70(1) : 41 – 55.
- [37] Wang X, Zhang R, Sun Y, et al. Doubly Robust Joint Learning for Recommendation on Data Missing Not at Random[A]. Proceedings of the 36th International Conference on Machine Learning[C] : Vol 97. 2019 : 6638 – 6647.
- [38] Saito Y. Doubly Robust Estimator for Ranking Metrics with Post-Click Conversions[A]. Proceedings of the 14th ACM Conference on Recommender Systems[C]. 2020 : 92 – 100.
- [39] Robins J M, Rotnitzky A, Zhao L P. Estimation of Regression Coefficients When Some Regressors Are Not Always Observed[J]. Journal of the American Statistical Association, 1994, 89(427) : 846 – 866.
- [40] 苗忠琦, 童向荣. 一种偏差和方差双降的双鲁棒去偏学习模型 [J/OL]. 小型微型计算机系统, 2024, 45(11) : 2663 – 2672. <http://dx.doi.org/10.20009/j.cnki.21-1106/TP.2023-0282>.
- [41] Dai Q, Li H, Wu P, et al. A Generalized Doubly Robust Learning Framework for Debiasing Post-Click Conversion Rate Prediction[A]. KDD '22: The 28th ACM

- SIGKDD Conference on Knowledge Discovery and Data Mining, Washington, DC, USA, August 14 - 18, 2022[C]. 2022 : 252 – 262.
- [42] Guo S, Zou L, Liu Y, et al. Enhanced Doubly Robust Learning for Debiasing Post-Click Conversion Rate Estimation[A]. Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval[C]. 2021 : 1797 – 1806.
- [43] Li H, Lyu Y, Zheng C, et al. TDR-CL: Targeted Doubly Robust Collaborative Learning for Debaised Recommendations[A]. . 2023.
- [44] Li H, Zheng C, Wu P. StableDR: Stabilized Doubly Robust Learning for Recommendation on Data Missing Not at Random[A]. . 2023.
- [45] Imai K, Ratkovic M. Covariate balancing propensity score[J]. Journal of the Royal Statistical Society Series B, 2014, 76(1) : 243 – 263.
- [46] Li H, Xiao Y, Zheng C, et al. Propensity Matters: Measuring and Enhancing Balancing for Recommendation[A]. Proceedings of the 40th International Conference on Machine Learning[C] : Vol 202. 2023 : 20182 – 20194.
- [47] Fong C, Hazlett C, Imai K. Covariate balancing propensity score for a continuous treatment: Application to the efficacy of political advertisements[J]. The Annals of Applied Statistics, 2018, 12(1) : 156 – 177.
- [48] Kuang K, Cui P, Li B, et al. Estimating Treatment Effect in the Wild via Differentiated Confounder Balancing[A]. Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining[C]. 2017 : 265 – 274.
- [49] Kuang K, Cui P, Li B, et al. Treatment Effect Estimation with Data-Driven Variable Decomposition[A]. AAAI Conference on Artificial Intelligence[C]. 2017 : 140 – 146.
- [50] Chang Y, Dy J G. Informative subspace learning for counterfactual inference[A]. Proceedings of the Thirty-First AAAI Conference on Artificial Intelligence[C]. 2017 : 1770 – 1776.

- [51] Li S, Vlassis N, Kawale J, et al. Matching via dimensionality reduction for estimation of treatment effects in digital marketing campaigns[A]. Proceedings of the Twenty-Fifth International Joint Conference on Artificial Intelligence[C]. 2016 : 3768–3774.
- [52] Li Q, Wang Z, Liu S, et al. Deep treatment adaptive network for causal inference[J]. VLDBJ, 2022 : 1–16.
- [53] Assaad S, Zeng S, Tao C, et al. Counterfactual representation learning with balancing weights[A]. International Conference on Artificial Intelligence and Statistics[C]. 2021 : 1972–1980.
- [54] Wang H, Chen Z, Fan J, et al. Optimal Transport for Treatment Effect Estimation[A]. Thirty-seventh Conference on Neural Information Processing Systems[C]. 2023 : 5404–5418.
- [55] Wang F, Chen C, Liu W, et al. CE-RCFR: Robust counterfactual regression for consensus-enabled treatment effect estimation[A]. Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining[C]. 2024 : 3013–3023.
- [56] Wu A, Kuang K, Xiong R, et al. Stable estimation of heterogeneous treatment effects[A]. International Conference on Machine Learning[C]: Vol 202. 2023 : 37496–37510.
- [57] Saito Y, Joachims T. Counterfactual Evaluation and Learning for Interactive Systems: Foundations, Implementations, and Recent Advances[A]. Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining[C]. 2022 : 4824–4825.
- [58] Wang Z, Zhang J, Xu H, et al. Counterfactual Data-Augmented Sequential Recommendation[A]. Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval[C]. 2021.
- [59] Wang W, Lin X, Feng F, et al. Causal Representation Learning for Out-of-Distribution Recommendation[A]. Proceedings of The Web Conference 2022[C].

- 2022.
- [60] Bonner S, Vasile F. Causal embeddings for recommendation[A]. Proceedings of the 12th ACM Conference on Recommender Systems[C]. 2018 : 104 – 112.
- [61] Bonner S, Vasile F. Causal embeddings for recommendation[A]. Proceedings of the 12th ACM Conference on Recommender Systems[C]. 2018 : 104 – 112.
- [62] Si Z, Han X, Zhang X, et al. A Model-Agnostic Causal Learning Framework for Recommendation using Search Data[A]. Proceedings of The Web Conference 2022[C]. 2022.
- [63] Saito Y, Yaginuma S, Nishino Y, et al. Unbiased Recommender Learning from Missing-Not-At-Random Implicit Feedback[A]. Proceedings of the 13th ACM International Conference on Web Search and Data Mining[C]. 2020.
- [64] Yang M, Dai Q, Dong Z, et al. Top-N Recommendation with Counterfactual User Preference Simulation[A]. . 2021.
- [65] Wang W, Feng F, He X, et al. Clicks can be Cheating: Counterfactual Recommendation for Mitigating Clickbait Issue[A]. Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval[C]. 2021 : 494 – 503.
- [66] Wei T, Feng F, Chen J, et al. Model-Agnostic Counterfactual Reasoning for Eliminating Popularity Bias in Recommender System[A]. Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery and Data Mining[C]. 2021 : 1791 – 1800.
- [67] Zhang Y, Feng F, He X, et al. Causal Intervention for Leveraging Popularity Bias in Recommendation[A]. Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval[C]. 2021.
- [68] Li H, Xiao Y, Zheng C, et al. Balancing Unobserved Confounding with a Few Unbiased Ratings in Debiased Recommendations[A]. Proceedings of The Web Conference 2023[C]. 2023.

- [69] Li H, Dai Q, Li Y, et al. Multiple robust learning for recommendation[A]. Proceedings of the Thirty-Seventh AAAI Conference on Artificial Intelligence[C]. 2023.
- [70] Chen J, Dong H, Qiu Y, et al. AutoDebias: Learning to Debias for Recommendation[A]. Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval[C]. 2021.
- [71] Liu D, Cheng P, Zhu H, et al. Mitigating Confounding Bias in Recommendation via Information Bottleneck[A]. Proceedings of the 15th ACM Conference on Recommender Systems[C]. 2021 : 351 – 360.
- [72] Kallus N. DeepMatch: Balancing Deep Covariate Representations for Causal Inference Using Adversarial Training[A]. Proceedings of the 37th International Conference on Machine Learning[C] : Vol 119. 2020 : 5067 – 5077.
- [73] He Y, Wang Z, Cui P, et al. CausPref: Causal Preference Learning for Out-of-Distribution Recommendation[A]. Proceedings of The Web Conference 2022[C]. 2022.
- [74] Jadidinejad A H, Macdonald C, Ounis I. The Simpson’ s Paradox in the Offline Evaluation of Recommendation Systems[J]. ACM Trans. Inf. Syst., 2021, 40(1).
- [75] 李金忠, 刘关俊, 闫春钢, et al. 排序学习研究进展与展望 [J/OL]. 自动化学报, 2018, 44(08) : 1345 – 1369. <http://dx.doi.org/10.16383/j.aas.2018.c170246>.
- [76] Li Y, Chen H, Xu S, et al. Towards Personalized Fairness based on Causal Notion[A]. Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval[C]. 2021 : 1054 – 1063.
- [77] Cao Z, Qin T, Liu T-Y, et al. Learning to rank: from pairwise approach to list-wise approach[A]. Proceedings of the 24th International Conference on Machine Learning[C]. 2007 : 129 – 136.
- [78] Zhang S, Yao D, Zhao Z, et al. CauseRec: Counterfactual User Sequence Synthesis for Sequential Recommendation[A]. Proceedings of the 44th International

- ACM SIGIR Conference on Research and Development in Information Retrieval[C]. 2021 : 367–377.
- [79] Wang H, Kuang K, Lan L, et al. Out-of-distribution generalization with causal feature separation[J]. TKDE, 2023.
- [80] Xie X, Liu Z, Wu S, et al. CausCF: Causal collaborative filtering for recommendation effect estimation[A]. Proceedings of the 30th ACM International Conference on Information and Knowledge Management[C]. 2021 : 4253–4263.
- [81] Rubin D B. Causal inference using potential outcomes: Design, modeling, decisions[J]. Journal of the American Statistical Association, 2005, 100(469) : 322–331.
- [82] 曹小敏, 刘进锋. 基于因果推断的两阶段长尾分类研究.[J]. Journal of Zhengzhou University (Natural Science Edition), 2024, 56(5).
- [83] Parikh N, Boyd S. Proximal Algorithms[J]. Foundations and Trends® in Optimization, 2014, 1(3) : 127–239.
- [84] Huang Z, Wang N. Data-driven sparse structure selection for deep neural networks[A]. Proceedings of the European Conference on Computer Vision[C]. 2018 : 304–320.
- [85] Cuturi M. Sinkhorn distances: Lightspeed computation of optimal transport[J]. Advances in neural information processing systems, 2013, 26.
- [86] Hillstrom K. The MineThatData E-mail Analytics and Data Mining Challenge[A]. MineThatData blog[C]. 2008.
- [87] Harper F M, Konstan J A. The MovieLens Datasets: History and Context[J], 2015, 5(4).
- [88] He X, Liao L, Zhang H, et al. Neural Collaborative Filtering[A]. Proceedings of the 26th International Conference on World Wide Web[C]. 2017 : 173–182.
- [89] Yao L, Li S, Li Y, et al. Representation learning for treatment effect estimation from observational data[A]. Advances in Neural Information Processing Systems[C]. 2018 : 2638–2648.

- [90] Wang H, Chen Z, Shen Y, et al. Proximity Matters: Local Proximity Preserved Balancing for Treatment Effect Estimation[J]. arXiv preprint arXiv:2407.01111, 2024.
- [91] Vayer T, Chapel L, Flamary R, et al. Fused Gromov-Wasserstein Distance for Structured Objects[J]. Algorithms, 2020, 13(9).
- [92] Mémoli F. Gromov-Wasserstein distances and the metric approach to object matching[J]. Foundations of computational mathematics, 2011, 11 : 417–487.
- [93] Chen L, Gan Z, Cheng Y, et al. Graph Optimal Transport for Cross-Domain Alignment[A]. Proceedings of the 37th International Conference on Machine Learning[C] : Vol 119. 2020 : 1542–1553.
- [94] Bonneel N, van de Panne M, Paris S, et al. Displacement interpolation using Lagrangian mass transport[J]. ACM Trans. Graph., 2011, 30(6) : 1–12.
- [95] Abrevaya J, Hsu Y-C, Lieli R P. Estimating conditional average treatment effects[J]. Journal of Business & Economic Statistics, 2015, 33(4) : 485–505.

作者简历

教育经历:

- 2023.09 – 至今 浙江大学 电子信息（硕士）
2019.09 – 2023.06 西南石油大学 计算机技术与科学（本科）

工作经历:

- 2024.06 – 2024.09 阿里巴巴国际电商事业群 AE 技术部后端开发实习生

攻读学位期间发表的论文或研究成果:

- 1 学生第一发明人. “一种基于最优传输的推荐系统公平增益模型训练方法及装置.” 中国发明专利（对应第三章）
- 2 学生三作. “Inter- and Intra- Similarity Preserved Counterfactual Incentive Effect Estimation for Recommendation Systems.” *ACM Transactions on Information Systems (TOIS)*, 2025. (CCF-A 类期刊, 对应第四章)

致 谢

行文至此，落笔为终。回首在浙江大学软件学院的求学时光，从初入校园的懵懂憧憬，到此刻完成学业的释然与不舍，这段旅程不仅是我学术生涯的重要篇章，更是我人生中一段熠熠生辉的记忆。

首先，我要向我的导师致以最崇高的敬意和最深切的感谢。在攻读硕士学位期间，从选题的斟酌、框架的搭建，到实验的细节与论文的字句推敲，导师始终给予我耐心的指导与无私的帮助。老师严谨治学的态度、敏锐的学术洞察力以及宽厚待人的长者风范，不仅指引我在科研道路上不断前行，更教会了我为人处世的道理，这些宝贵的精神财富将令我受用终生。

特别地，我想感谢带领我科研的学姐。在我初涉科研、深感迷茫之际，是你耐心地引领我通过了学术的入门关。从最初文献阅读的方法、实验代码的调试，到论文逻辑的梳理，每一次遇到瓶颈时，你总是毫无保留地给予我指导与建议。

感谢学院为我们提供了优越的学习环境与广阔的学术平台。在这里，我有幸聆听诸多学者的真知灼见，感受求是园中浓厚的学术氛围。感谢实验室的同门师兄姐妹们，是你们在无数个日夜的探讨与协作中，给予我灵感的火花与精神的支持。无论是科研攻关时的相互鼓励，还是生活中的欢声笑语，都让这段枯燥的求学路变得温暖而充实。

特别感谢我的父母与家人。你们始终是我最强有力的后盾，是你们无条件的爱、包容与支持，让我能够心无旁骛地追逐梦想。无论遇到何种挫折，只要想到家人的期盼与目光，我便拥有了重新出发的勇气。

最后，感谢所有关心、帮助过我的朋友和同学，也感谢未曾轻言放弃的自己。

凡是过往，皆为序章。带着浙大“求是创新”的校训，我将怀揣着这份感恩与所学，奔赴下一场山海，在未来的道路上脚踏实地，不负韶华。